

UNIVERSIDAD INTERCONTINENTAL DE LA EMPRESA



FACULTAD DE INGENIERÍA Y TECNOLOGÍA EMPRESARIAL

**TRABAJO FIN DE GRADO EN
INGENIERÍA EN SISTEMAS INTELIGENTES**

**Predicción de demanda de empresa de producción de
neumáticos en Suiza**

Autor:

Manuel Roncero Gago

Director(es):

David Esteban Martínez



Esta obra se encuentra sujeta a la licencia *Creative Commons* (CC-BY-NC-ND)

Compartir-Reconocimiento-No Comercial-Sin Obra Derivada

RESUMEN

En el trabajo se analiza y predice la demanda de neumáticos por zonas geográficas en el mercado suizo, desarrollado en el marco de las prácticas curriculares en SDG Group para un cliente del sector de automoción. El mercado suizo presenta características singulares: una marcada estacionalidad bimodal asociada a su climatología alpina, alta heterogeneidad territorial entre los 26 cantones y un parque vehicular con tendencia creciente hacia la premiumización y la electrificación.

El trabajo comprende cuatro fases principales. En primer lugar, se realizó una preparación exhaustiva de los datos, incluyendo filtrado, anonimización de información confidencial y enriquecimiento geográfico mediante técnicas de unión espacial. En segundo lugar, se llevó a cabo un análisis exploratorio multidimensional que abarca las dimensiones temporal, geográfica y de producto, identificando patrones estacionales, oportunidades de mercado por cantón y tendencias estructurales como la migración hacia llantas de mayor diámetro y la premiumización acelerada.

En tercer lugar, se construyó y validó un sistema de predicción basado en un conjunto de modelos que combina XGBoost con optimización bayesiana, XGBoost con variables macroeconómicas y del parque vehicular, SARIMA, SARIMAX, suavizado exponencial y regresión Ridge, seleccionando el modelo óptimo para cada cantón. La validación se realizó mediante validación cruzada temporal con tres cortes, obteniendo un error medio del 28,8 por ciento en los cantones de mayor volumen, lo que supone una mejora del 42 por ciento respecto al modelo de referencia basado en la media histórica (50,9 por ciento) y sitúa los resultados dentro del rango considerado bueno en la literatura de predicción de demanda industrial. Finalmente, se desarrolló un panel interactivo en Tableau Public y un agente conversacional basado en la API de Claude que actúa como capa de interpretación inteligente, permitiendo obtener resúmenes y análisis de fiabilidad mediante lenguaje natural.

Palabras clave:

agente conversacional, análisis exploratorio de datos, ensemble, optimización bayesiana, predicción de demanda, SARIMA, series temporales, Suiza, neumáticos, XGBoost.

ABSTRACT

This thesis analyses and predicts tyre demand by geographic zones in the Swiss market, developed within the framework of a curricular internship at SDG Group for a client in the automotive sector. The Swiss market presents unique characteristics: a marked bimodal seasonality associated with its Alpine climate, high territorial heterogeneity across 26 cantons, and a vehicle fleet showing growing trends towards premiumisation and electrification.

The project encompasses four main phases. First, an exhaustive data preparation process was carried out, including filtering, anonymisation of confidential information, and geographic enrichment through spatial join techniques. Second, a multi-dimensional exploratory data analysis was performed covering temporal, geographic, and product dimensions, identifying seasonal patterns, market opportunities by canton, and structural trends such as the migration towards larger rim diameters and accelerated premiumisation.

Third, a prediction system was built and validated based on an ensemble of models combining XGBoost with Bayesian optimisation, XGBoost with macroeconomic and vehicle fleet variables, SARIMA, SARIMAX, exponential smoothing, and Ridge regression, selecting the optimal model for each canton. Validation was performed through time series cross-validation with three temporal splits, achieving a mean error of 28.8 percent for the largest cantons, representing a 42 percent improvement over the historical mean baseline (50.9 percent) and placing the results within the range considered good in the industrial demand forecasting literature. Finally, an interactive dashboard was developed in Tableau Public and a conversational agent based on the Claude API was built to act as an intelligent interpretation layer, enabling summaries and reliability analysis through natural language queries.

Keywords:

Bayesian optimisation, conversational agent, demand forecasting, ensemble, exploratory data analysis, SARIMA, Switzerland, time series, tyres, XGBoost.

ÍNDICE DE CONTENIDOS

RESUMEN	II
ABSTRACT	III
ÍNDICE DE FIGURAS	X
ÍNDICE DE TABLAS	XI
1 INTRODUCCIÓN	1
1.1 Motivación del trabajo	1
1.2 Planteamiento del problema	1
1.3 Objetivos	2
1.3.1 Objetivo general	2
1.3.2 Objetivos específicos	2
1.4 Antecedentes	2
1.5 Metodología	3
1.5.1 CRISP-DM	3
1.5.2 Aplicación de CRISP-DM al proyecto	3
1.6 Organización del documento	4
2 MARCO TEÓRICO	5
2.1 Análisis de datos	5
2.1.1 Concepto y proceso general	5
2.1.2 Análisis exploratorio de datos (EDA)	5
2.1.3 Conceptos técnicos relevantes	6
2.2 Predicción de series temporales	6
2.2.1 Predicción	6
2.2.2 Series temporales	6
2.2.3 Modelos predictivos	6
2.2.4 Modelos ARIMA, SARIMA y SARIMAX	7
2.2.5 Suavizado exponencial (ETS)	7
2.3 Aprendizaje automático para series temporales	7
2.3.1 Aprendizaje automático	7
2.3.2 XGBoost	7
2.3.3 Regresión Ridge	8
2.4 Optimización de hiperparámetros	8
2.4.1 Hiperparámetros e importancia de su optimización	8
2.4.2 Grid Search	8
2.4.3 Optimización bayesiana (Optuna)	8

2.5	Modelos de conjunto	9
2.6	Validación de modelos de series temporales	9
2.6.1	Importancia de la validación	9
2.6.2	Validación cruzada	9
2.6.3	Validación cruzada walk-forward	10
2.6.4	MAPE	10
2.7	Visualización de datos	10
2.8	Agentes conversacionales y modelos de lenguaje	11
2.9	Herramientas y tecnologías	12
3	ANÁLISIS DE LA SITUACIÓN	13
3.1	Descripción detallada del problema	13
3.1.1	Datasets disponibles	13
3.1.1.1	Sell In	13
3.1.1.2	Sell Out	14
3.1.1.3	Customer Master	14
3.1.1.4	Carpark	14
3.1.1.5	Tire Potential	15
3.1.2	Contexto y características del mercado suizo	15
3.2	Requisitos	16
3.2.1	Requisitos funcionales	16
3.2.2	Requisitos no funcionales	16
3.3	Solución propuesta	17
4	DESARROLLO	18
4.1	Preparación y limpieza de datos	18
4.1.1	Entorno de trabajo	18
4.1.2	Carga y diagnóstico inicial	18
4.1.3	Corrección de tipos de dato	18
4.1.4	Anonimización de datos sensibles	19
4.1.5	Enriquecimiento geográfico	19
4.1.5.1	Asignación de cantón al Sell Out	19
4.1.5.2	Asignación de cantón al Sell In	19
4.1.5.3	Unión espacial para asignación cantonal	20
4.2	Análisis Exploratorio de Datos	21
4.2.1	Proceso de análisis temporal	21
4.2.1.1	Construcción de series temporales agregadas	21
4.2.1.2	Análisis de correlación con temperatura	22
4.2.1.3	Análisis de la diferencia Sell In - Sell Out	22
4.2.2	Proceso de análisis geográfico	23
4.2.2.1	Análisis de concentración por código postal	23
4.2.2.2	Identificación del outlier logístico	23
4.2.2.3	Construcción del mapa de calor	24
4.2.2.4	Análisis de penetración vs Tire Potential	24

4.2.3	Proceso de análisis de producto	25
4.2.3.1	Exploración de columnas de producto	25
4.2.3.2	Análisis de la anomalía de mayo 2025	25
4.2.3.3	Distribución del diámetro de llanta (RIM)	26
4.3	Modelado predictivo	26
4.3.1	Construcción del dataframe maestro	26
4.3.2	Feature engineering	27
4.3.2.1	Features v1 — Base temporal y climática	27
4.3.2.2	Features v2 — Enriquecimiento macroeconómico	28
4.3.3	Partición train-test	28
4.3.4	Bases	29
4.3.5	XGBoost global — Primera iteración	29
4.3.6	Estratificación de cantones	30
4.3.7	XGBoost v1 en cantones grandes y Grid Search	30
4.3.8	SARIMA por cantón	31
4.3.9	Conjunto de modelos v1	32
4.3.10	XGBoost v2 con variables macroeconómicas	32
4.3.11	Evaluación de SARIMAX	32
4.3.12	Optimización bayesiana con Optuna	33
4.3.13	Validación Cruzada Walk-forward	34
4.3.14	Ensemble definitivo	34
4.4	Panel de control en Tableau Public	35
4.4.1	Preparación de los CSVs para Tableau	35
4.4.2	Construcción de las vistas	35
4.4.3	Implementación de filtros globales	37
4.5	Agente conversacional	37
4.5.1	Arquitectura del sistema	37
4.5.2	Diseño del system prompt	37
4.5.3	Integración con Tableau	39
5	RESULTADOS	40
5.1	Resultados del análisis exploratorio de datos	40
5.1.1	Análisis temporal	40
5.1.2	Análisis geográfico	42
5.1.3	Análisis de producto	43
5.2	Resultados del modelado predictivo	44
5.2.1	Comparativa de modelos	44
5.2.2	Ensemble definitivo	44
5.2.3	Predicciones para el período marzo 2026 - febrero 2027	45
5.3	Resultados del panel de control	46
5.4	Resultados del agente conversacional	47
5.5	Comparativa con trabajos similares	49
6	CONCLUSIONES y TRABAJOS FUTUROS	50

6.1	Conclusiones	50
6.2	Objetivos cumplidos	51
6.3	Trabajos futuros	51
7	BIBLIOGRAFÍA	52
8	ANEXOS	54
A	Declaración de uso de IAG	55
B	Repositorio y panel de control	56
C	Parámetros del ensemble definitivo	57

ÍNDICE DE FIGURAS

2.1	Esquema de la validación walk-forward con tres cortes temporales. En cada iteración el conjunto de entrenamiento crece y el test evalúa el período inmediatamente posterior. . . .	10
4.1	Volumen mensual en unidades de Sell In (azul) y Sell Out (verde) en Suiza (2023-2026). Se aprecian el patrón bimodal estacional y el desfase de aproximadamente dos meses entre el aprovisionamiento del canal y la venta al consumidor final.	21
4.2	Correlación entre ventas y temperatura con retardo de 2 meses para el tipo de neumáticos Winter (izquierda) y Summer (derecha).	22
4.3	Estacionalidad normalizada del Sell Out por año (2022-2025). Los cuatro años muestran un patrón prácticamente idéntico.	22
4.4	Concentración de volumen en Sell-In y Sell-Out	23
4.5	Diferencia normalizada entre Sell Out y Tire Potential por cantón (sin Solothurn, 2024-2026). La métrica indica cuánto se aleja el volumen real del potencial estimado del mercado: verde = Sell Out por debajo del potencial (oportunidad de crecimiento), rojo = Sell Out por encima (alta penetración).	24
4.6	Cantones que están por debajo del 100 % presentan una oportunidad de mercado, mientras las que están por encima están suficientemente abastecidos	24
4.7	Evolución del mix de tier de marca por año (2018-2026). Premium pasa del 28 % al 80 % en el período analizado.	25
4.8	Evolución temporal por tipo de vehículo	25
4.9	Distribución de diámetro de llanta (RIM) y evolución del mix por año (2019-2026).	26
4.10	Esquema de la validación cruzada walk-forward con tres cortes temporales aplicada en el proyecto.	34
4.11	Vista Serie_Temporal del panel de control de Tableau Public. Muestra el histórico de Sell Out (azul) y las predicciones (naranja) por cantón, con línea de referencia vertical marcando el inicio del período de predicción (marzo 2026).	35
4.12	Vista Mapa_Prediccion del panel de control de Tableau Public. Círculos proporcionales a la predicción de demanda a 12 meses posicionados sobre el mapa de Suiza. La descripción muestra cantón, predicción, modelo asignado y MAPE.	36
4.13	Vista Mix_Producto del panel de control de Tableau Public. Barras apiladas al 100 % mostrando la evolución del mix de tier de marca (Premium, Quality, Budget) por año, filtrable por cantón.	36
4.14	Vista Estacionalidad_Tipo del panel de control de Tableau Public. Curvas de demanda relativa por tipo de neumático (Winter, Summer, All Season) según el mes del año.	36
4.15	Vista Modelos_MAPE del panel de control de Tableau Public. Barras horizontales del MAPE walk-forward por cantón, coloreadas por modelo asignado. La línea discontinua marca el umbral de aceptabilidad del 50 %.	36
5.1	Estacionalidad normalizada del Sell Out por año (2022-2025). Los cuatro años muestran un patrón prácticamente idéntico, confirmando la estabilidad de la demanda bimodal.	40

5.2	Correlación entre ventas y temperatura con lag de 2 meses para neumáticos Winter (izquierda) y Summer (derecha).	40
5.3	La gráfica superior representa el volumen mensual de Sell In y Sell Out, donde se puede observar la tendencia bajista en cuanto al stock presente en las empresas. La inferior representa la acumulación (negativa o positiva), que hace que sugiera que sea un ajuste de inventario por los grandes volúmenes de aprovisionamiento previos	41
5.4	La gráfica superior representa la evolución del precio medio de los neumáticos donde se puede ver la tendencia alcista del precio. La inferior muestra el precio medio por mes del precio medio de los neumáticos lo que muestra consistencia en ellos y apuntando a que el crecimiento del precio es debido a temas inflacionarios.	41
5.5	Diferencia normalizada Sell Out vs Tire Potential por cantón (sin Solothurn por efecto logístico). Verde = potencial de crecimiento, rojo = alta penetración de las empresas reportantes. . . .	42
5.6	Evolución de la mezcla por tipo de neumático por año (2018-2026). Premium pasa del 28 % al 80 % en el período analizado, con el sorpasso sobre Quality en 2019.	43
5.7	Evolución del diámetro de llanta (RIM) por año (2019-2026). RIM 16 cae del 37 % al 22 % mientras RIM 18 sube del 10 % al 21 %.	43
5.8	Ensemble definitivo: MAPE walk-forward por cantón (izquierda) y distribución de modelos asignados (derecha). La línea discontinua marca el umbral del 50 %.	45
5.9	Mapa de predicción de demanda a 12 meses por cantón (izquierda, sin Solothurn por efecto logístico) y MAPE walk-forward por cantón (derecha). Verde = mejor precisión.	46
5.10	Vista general del panel de control principal en Tableau Public con los filtros globales de cantón y modelo activos en la parte superior.	47
5.11	Interfaz del agente conversacional en funcionamiento: panel de chat (izquierda) y panel de control de Tableau integrado (derecha).	48
5.12	Gráfica de análisis generada automáticamente por el agente tras la consulta sobre Uri. El agente recomendó la vista de MAPE por cantón para contextualizar la fiabilidad.	49

ÍNDICE DE TABLAS

3.1	Resumen de los datasets disponibles para el proyecto.	13
4.1	MAPE del XGBoost global por cantón (selección). El modelo falla especialmente en cantones de bajo volumen.	30
4.2	Comparativa SARIMA vs XGBoost v1 en cantones grandes. El ganador por cantón queda resaltado.	31
4.3	Comparativa SARIMA vs SARIMAX. Solo Vaud mejora con la incorporación de variables exógenas.	33
4.4	Evolución del MAPE de XGBoost a lo largo del proceso de optimización de hiperparámetros.	33
4.5	Comprobaciones realizadas antes de cerrar el ensemble definitivo.	35
5.1	Comparativa de MAPE walk-forward por modelo. Grandes: 13 cantones con volumen medio $\geq$ 500 uds/mes. Todos: los 26 cantones. Global: promedio del conjunto de modelos(Ensemble) con el modelo óptimo por cantón. El mejor resultado de cada grupo se muestra en negrita.	44
5.2	Predicciones de demanda a 12 meses por cantón (marzo 2026 - febrero 2027).	46
C.1	Hiperparámetros de los modelos XGBoost en el ensemble definitivo.	57

1 INTRODUCCIÓN

1.1 Motivación del trabajo

La predicción de la demanda es uno de los problemas más relevantes en la gestión de la cadena de suministro. En un entorno económico marcado por la volatilidad de los mercados, la presión sobre los márgenes y la creciente exigencia del consumidor final, la capacidad de anticipar la demanda con precisión se ha convertido en una ventaja competitiva determinante para las empresas distribuidoras. La digitalización de los canales de venta y la disponibilidad masiva de datos transaccionales han abierto la puerta a enfoques basados en aprendizaje automático que superan las limitaciones de los métodos estadísticos tradicionales, especialmente en contextos con alta heterogeneidad geográfica o estacionalidad compleja.

En el sector de automoción, y específicamente en la distribución de neumáticos, esta problemática adquiere una dimensión adicional: la demanda está fuertemente condicionada por factores externos como la climatología, la evolución del parque vehicular y las tendencias estructurales del mercado (electrificación, premiumización, SUVización), que varían de forma significativa entre regiones. La capacidad de anticipar la demanda por zona geográfica permite optimizar el aprovisionamiento, reducir el exceso de stock y mejorar el nivel de servicio al cliente final, con un impacto directo en la rentabilidad operativa de la empresa distribuidora.

Este trabajo surge de la necesidad real de un cliente del sector de neumáticos de disponer de un sistema de análisis y predicción de la demanda desagregada a nivel de cantón para el mercado suizo. El proyecto se desarrolla en el marco de las prácticas curriculares en SDG Group, consultora especializada en analítica de datos, lo que proporciona acceso a datos reales de ventas y un contexto empresarial auténtico.

El mercado suizo presenta características que lo convierten en un caso de estudio especialmente rico: su geografía alpina genera una estacionalidad bimodal muy marcada, cambio a neumáticos de invierno en otoño y de verano en primavera, sus 26 cantones tienen perfiles socioeconómicos y de movilidad muy distintos, y el parque vehicular muestra tendencias estructurales claras como la premiumización y la electrificación creciente. Estas características hacen que la predicción a nivel cantonal sea un problema metodológicamente exigente y académicamente relevante.

1.2 Planteamiento del problema

El problema central es la estimación del volumen de neumáticos demandado mensualmente por cantón en Suiza para un horizonte de 12 meses. Los datos disponibles proceden de cuatro fuentes principales: datos de venta a distribuidores (sell-in), datos de venta al consumidor final (sell-out), información del parque de vehículos (carpark) y estimaciones del potencial de mercado (tire potential).

El problema presenta varias dificultades específicas:

- **Heterogeneidad territorial:** los 26 cantones presentan volúmenes de demanda muy distintos, desde más de 5.000 unidades mensuales en los cantones más grandes hasta menos de 10 en los más pequeños, lo que impide aplicar un modelo único para todos.
- **Datos confidenciales:** los datos provienen de un cliente empresarial y contienen información sensible que requiere anonimización previa al análisis.

- **Cobertura parcial del mercado:** el *sell-out* solo recoge las ventas de seis empresas que voluntariamente reportan información, no la demanda total del mercado suizo.
- **Estacionalidad compleja:** cada tipo de neumático (invierno, verano, todoterreno) tiene su propio patrón estacional, con correlaciones significativas con variables climáticas con desfase temporal.
- **Outliers logísticos:** la presencia de centros de distribución en determinados códigos postales (como Härkingen en Solothurn, que concentra el 17,2 % del *sell-out* total) distorsiona el análisis geográfico.

1.3 Objetivos

1.3.1 Objetivo general

Desarrollar un sistema de análisis y predicción de la demanda de neumáticos por zonas geográficas en el mercado suizo, a partir de datos reales de ventas, con el fin de identificar patrones territoriales y estimar la demanda futura por cantón.

1.3.2 Objetivos específicos

1. Preparar y limpiar el conjunto de datos de partida, garantizando su calidad, coherencia y confidencialidad para el análisis posterior.
2. Realizar un análisis exploratorio multidimensional que permita caracterizar la situación actual del mercado suizo e identificar patrones geográficos, estacionales y de producto por zona.
3. Construir y validar modelos predictivos de demanda a nivel de cantón, comparando distintos enfoques metodológicos mediante validación cruzada con ventana deslizante (walk-forward cross-validation).
4. Implementar un panel de control interactivo en Tableau Public (Tableau Software, LLC, 2024) que permita visualizar el análisis histórico, las predicciones y la evaluación técnica de los modelos de forma clara y accionable para la empresa.
5. Desarrollar un agente conversacional basado en la API de Claude que proporcione interpretaciones automáticas de los resultados del dashboard, resúmenes por cantón y gráficas de análisis bajo demanda, actuando como capa de soporte inteligente sobre la herramienta de visualización.

1.4 Antecedentes

La predicción de demanda en series temporales con estacionalidad es un problema ampliamente estudiado. Los enfoques clásicos incluyen los modelos ARIMA (Autoregressive Integrated Moving Average) y sus extensiones estacionales (Box et al., 2015), los modelos de suavizado exponencial (Holt, 2004) y los métodos de descomposición de series. Con el auge del aprendizaje automático, modelos como XGBoost (Chen & Guestrin, 2016) han demostrado resultados competitivos en predicción de series temporales cuando se acompañan de un feature engineering adecuado basado en retardos y ventanas temporales.

La combinación de múltiples modelos mediante un conjunto de modelos (comunmente llamados ensemble por su nombre en inglés) es una práctica consolidada que permite superar las limitaciones individuales de cada modelo como se ve en la competición M4 (Makridakis et al., 2018), donde los métodos híbridos que combinan modelos estadísticos con redes neuronales obtuvieron los mejores resultados, lo que motivó la adopción de este enfoque en el presente trabajo.

La optimización bayesiana de hiperparámetros mediante surrogate models (Snoek et al., 2012) ha demostrado ser más eficiente que la búsqueda exhaustiva (grid search) para espacios de parámetros de alta dimensionalidad, es decir, cuando el número de hiperparámetros a optimizar es grande y las combinaciones posibles crecen exponencialmente, especialmente cuando el coste computacional de cada evaluación es elevado.

En el contexto específico de la predicción de demanda en la industria del automóvil, Syntetos y Boylan (2005) destacan la importancia de considerar la intermitencia de la demanda en productos con alta variabilidad, fenómeno que se manifiesta claramente en los cantones de menor volumen de este trabajo.

1.5 Metodología

1.5.1 CRISP-DM

El proyecto sigue la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), es el estándar en proyectos de ciencia de datos y minería de datos desde su publicación en 1999 (Wirth & Hipp, 2000). CRISP-DM define un proceso iterativo estructurado en seis fases que guían el desarrollo de proyectos de análisis de datos desde la comprensión del problema hasta el despliegue de la solución:

1.5.2 Aplicación de CRISP-DM al proyecto

Las seis fases de CRISP-DM se materializan en este proyecto de la siguiente forma:

Fase 1 — Comprensión del negocio: identificación de la necesidad del cliente de disponer de predicciones de demanda de neumáticos desagregadas por cantón para el mercado suizo, definición de los objetivos medibles (MAPE inferior al 50 % como umbral de aceptabilidad) y establecimiento de los requisitos de confidencialidad que condicionan el tratamiento de los datos.

Fase 2 — Comprensión de los datos: análisis exploratorio multidimensional de los cinco datasets disponibles (Sell In, Sell Out, Customer Master, Carpark y Tire Potential), identificación de la estacionalidad bimodal, el desfase entre canales, las tendencias estructurales de producto y los patrones geográficos de distribución.

Fase 3 — Preparación de los datos: filtrado por país, anonimización de datos confidenciales con mapeos consistentes entre datasets, enriquecimiento geográfico mediante uniones espaciales (Jordahl et al., 2021) con el shapefile (o archivo de formas, en español) oficial de cantones suizos (GADM, 2022), e integración de variables climáticas (Open-Meteo, 2022) y macroeconómicas (World Bank, 2023) en el dataframe maestro cantonal.

Fase 4 — Modelado: evaluación comparativa de seis familias de modelos (XGBoost con optimización bayesiana (Akiba et al., 2019), XGBoost con variables macroeconómicas, SARIMA, SARIMAX, ETS y Ridge), construcción del ensemble definitivo mediante selección del modelo óptimo por cantón y generación de predicciones a 12 meses con estrategia de predicción iterativa.

Fase 5 — Evaluación: validación cruzada con ventana deslizante (walk-forward cross-validation) con tres cortes temporales (Tashman, 2000), análisis de la fiabilidad por cantón y comparativa con los modelos base. Se identificaron cantones impredecibles por volumen insuficiente y se documentaron las limitaciones del sistema.

Fase 6 — Despliegue: desarrollo del panel de control interactivo en Tableau Public (Tableau Software, LLC, 2024) como capa de presentación empresarial y del agente conversacional basado en la API de Claude (Anthropic, 2024) como capa de interpretación inteligente, accesible mediante una aplicación web local desarrollada con Flask (Ronacher, 2010).

Todo el procesamiento y modelado se implementa en Python 3.11 (Chen & Guestrin, 2016; McKinney, 2010; Pedregosa et al., 2011; Seabold & Perktold, 2010) con un entorno gestionado por Anaconda (Anaconda, Inc., 2020) dedicado al proyecto.

1.6 Organización del documento

El documento se estructura de la siguiente manera. El Capítulo 2 presenta el marco teórico de los modelos y técnicas empleadas, incluyendo los modelos de series temporales, los algoritmos de aprendizaje automático, los métodos de optimización de hiperparámetros y las estrategias de validación. El Capítulo 3 describe el análisis de la situación, incluyendo los datos disponibles, los principales hallazgos del análisis exploratorio y los requisitos del sistema. El Capítulo 4 detalla el proceso de desarrollo completo, desde la preparación de datos hasta la construcción del ensemble definitivo, la generación de predicciones, el dashboard de Tableau y el agente conversacional. El Capítulo 5 recoge los resultados obtenidos en cada una de las fases del proyecto, incluyendo los hallazgos del análisis exploratorio, la evaluación del ensemble predictivo, las predicciones por cantón y las capacidades del agente conversacional. El Capítulo 6 presenta las conclusiones, el grado de cumplimiento de los objetivos y las líneas de trabajo futuro.

2 MARCO TEÓRICO

Este capítulo presenta los fundamentos teóricos necesarios para comprender el trabajo desarrollado, estructurados de lo más general a lo más específico: desde los conceptos de análisis y visualización de datos hasta los modelos predictivos, las técnicas de optimización y los agentes conversacionales.

2.1 Análisis de datos

El análisis de datos es la base sobre la que se construye todo el proyecto. Antes de poder predecir la demanda de neumáticos es necesario comprender los datos disponibles, su estructura, su calidad y sus patrones. Sin este paso previo no sería posible tomar decisiones fundamentadas sobre qué variables usar, qué modelos aplicar ni cómo interpretar los resultados.

2.1.1 Concepto y proceso general

El análisis de datos es el proceso sistemático de inspeccionar, limpiar, transformar e interpretar datos con el objetivo de descubrir información útil, identificar patrones y apoyar la toma de decisiones (McKinney, 2010). En el contexto de la ciencia de datos, el análisis precede siempre al modelado: un análisis riguroso permite identificar la naturaleza del problema, las características de los datos disponibles y las técnicas más adecuadas para abordarlo.

El proceso general de análisis de datos comprende las siguientes etapas:

1. **Recopilación:** obtención de los datos de las fuentes disponibles (bases de datos, APIs, ficheros).
2. **Limpeza:** detección y tratamiento de valores ausentes, duplicados, errores y outliers.
3. **Transformación:** normalización, agregación y creación de nuevas variables derivadas.
4. **Exploración:** análisis estadístico descriptivo y visualización para identificar patrones y relaciones.
5. **Interpretación:** traducción de los hallazgos técnicos en conclusiones accionables para el negocio.

2.1.2 Análisis exploratorio de datos (EDA)

El análisis exploratorio de datos (EDA, por sus siglas en inglés) es la fase del análisis en la que se estudia la estructura y distribución de los datos mediante estadísticos descriptivos y visualizaciones, sin imponer hipótesis previas sobre su comportamiento (McKinney, 2010). El objetivo del EDA es comprender los datos antes de modelarlos, identificando patrones relevantes, anomalías, correlaciones entre variables y posibles problemas de calidad que deban resolverse en la fase de preparación.

Las técnicas más habituales del EDA incluyen el análisis de distribuciones (histogramas, diagramas de caja), el estudio de correlaciones (matrices de correlación, diagramas de dispersión), el análisis de series temporales (descomposición estacional, gráficos de autocorrelación) y la detección de anomalías.

2.1.3 Conceptos técnicos relevantes

Los siguientes conceptos son especialmente relevantes para el análisis realizado en este proyecto:

Estacionalidad: patrón periódico que se repite con una frecuencia regular (mensual, trimestral, anual) en una serie temporal. En el mercado de neumáticos suizo la estacionalidad es bimodal y anual, con picos en primavera y otoño asociados al cambio de temporada.

Correlación: medida estadística que cuantifica la relación lineal entre dos variables. El coeficiente de correlación de Pearson toma valores entre -1 (correlación negativa perfecta) y $+1$ (correlación positiva perfecta). En este proyecto se utiliza para cuantificar la relación entre temperatura y demanda de neumáticos con distintos desfases temporales.

Anomalía: observación que se aleja significativamente del patrón general de los datos. Puede deberse a errores de medición o a fenómenos reales de interés.

Desfase temporal (lag): desplazamiento temporal entre dos series. En este proyecto se observa un desfase de aproximadamente dos meses entre el Sell In (aprovisionamiento) y el Sell Out (venta al consumidor final).

2.2 Predicción de series temporales

2.2.1 Predicción

La predicción (forecasting) es el proceso de estimar valores futuros de una variable a partir de un modelo entrenado con datos históricos. Se distingue de la interpolación en que los valores predichos corresponden a instantes temporales posteriores al último dato observado, lo que implica una mayor incertidumbre cuanto mayor es el horizonte de predicción. En este proyecto el horizonte de predicción es de 12 meses, lo que se considera predicción a medio plazo en la literatura de series temporales (Makridakis et al., 2018).

2.2.2 Series temporales

Una serie temporal es una secuencia de observaciones ordenadas cronológicamente. La predicción de series temporales consiste en estimar valores futuros a partir del comportamiento histórico de la serie y, en su caso, de variables externas correlacionadas (Box et al., 2015).

Las series temporales pueden descomponerse en cuatro componentes: tendencia (evolución a largo plazo), estacionalidad (variaciones periódicas regulares), ciclicidad (fluctuaciones de período variable) e irregularidad (variaciones aleatorias no explicadas por los componentes anteriores). En el caso de la demanda de neumáticos en Suiza, la estacionalidad es el componente dominante, con un patrón bimodal anual muy pronunciado asociado al cambio de temporada.

2.2.3 Modelos predictivos

Un modelo predictivo es una representación matemática o estadística que establece una relación entre un conjunto de variables de entrada y una variable de salida, con el objetivo de estimar el valor de dicha variable en situaciones no observadas previamente (Box et al., 2015). En el contexto de las series temporales, el modelo aprende el comportamiento histórico de una variable para extrapolar su evolución futura.

2.2.4 Modelos ARIMA, SARIMA y SARIMAX

Los modelos ARIMA (AutoRegressive Integrated Moving Average) combinan componentes autorregresivos, de integración y de media móvil para modelar series temporales estacionarias (Box et al., 2015). El modelo SARIMA extiende ARIMA incorporando términos estacionales, siendo especialmente adecuado para series con periodicidad anual como la demanda de neumáticos.

Un modelo SARIMA (Seasonal AutoRegressive Integrated Moving Average) $(p, d, q)(P, D, Q)_s$ se define por los órdenes del componente no estacional (p, d, q) y del componente estacional (P, D, Q) con período s . En este trabajo se emplea SARIMA(1, 1, 1)(1, 1, 1)₁₂, configuración estándar para series mensuales con estacionalidad anual.

SARIMAX (Seasonal AutoRegressive Integrated Moving Average eXogenous) es la extensión de SARIMA que permite incorporar variables exógenas, lo que posibilita integrar información externa como el índice de precios al consumo o el porcentaje de vehículos eléctricos en el parque vehicular.

2.2.5 Suavizado exponencial (ETS)

Los modelos de suavizado exponencial asignan pesos decrecientes exponencialmente a las observaciones pasadas, otorgando mayor importancia a las más recientes (Holt, 2004; Winters, 1960). El modelo ETS (Error, Trend, Seasonality) con componentes aditivos de tendencia y estacionalidad es especialmente robusto en series con patrones estacionales estables y tamaños muestrales reducidos, características presentes en los cantones de bajo volumen de este estudio.

2.3 Aprendizaje automático para series temporales

2.3.1 Aprendizaje automático

El aprendizaje automático (machine learning) es una rama de la inteligencia artificial que desarrolla algoritmos capaces de aprender patrones a partir de datos sin ser programados explícitamente para cada tarea (Pedregosa et al., 2011). A diferencia de los modelos estadísticos clásicos, que asumen una forma funcional fija para la relación entre variables, los algoritmos de aprendizaje automático son capaces de capturar relaciones no lineales y de alta dimensionalidad de forma automática.

En el contexto de la predicción de series temporales, el aprendizaje automático transforma el problema temporal en un problema de regresión supervisada: se construyen variables predictoras a partir del histórico de la serie (retardos, medias móviles, codificaciones temporales) y el modelo aprende la relación entre dichas variables y el valor futuro a predecir (Chen & Guestrin, 2016). Esta transformación permite incorporar variables externas de forma natural, superando una limitación importante de los modelos estadísticos clásicos como ARIMA.

2.3.2 XGBoost

XGBoost (eXtreme Gradient Boosting) es un algoritmo de gradient boosting basado en árboles de decisión que ha demostrado resultados de referencia en numerosas competiciones de predicción (Chen & Guestrin, 2016). Su aplicación a series temporales requiere transformar el problema en un formato tabular mediante la creación de variables retardadas (lags), ventanas móviles (rolling windows) y codificaciones temporales cíclicas.

La principal ventaja de XGBoost respecto a los modelos estadísticos es su capacidad para incorporar variables externas de forma natural, sin las restricciones de linealidad de ARIMA. Sin embargo, su aplicación directa a predicciones a largo plazo requiere estrategias específicas: en este trabajo se emplea la predicción iterativa (recursive forecasting), donde cada predicción mensual se utiliza como entrada para generar la del mes siguiente, preservando la señal estacional a lo largo del horizonte de predicción.

2.3.3 Regresión Ridge

La regresión Ridge es una extensión de la regresión lineal ordinaria que incorpora un término de regularización L_2 para penalizar la magnitud de los coeficientes (Hoerl & Kennard, 1970). Resulta especialmente útil cuando el número de variables predictoras es elevado en relación con el número de observaciones, situación habitual en cantones con series temporales cortas.

2.4 Optimización de hiperparámetros

2.4.1 Hiperparámetros e importancia de su optimización

Los hiperparámetros son parámetros de configuración de un modelo de aprendizaje automático que no se aprenden durante el entrenamiento sino que deben ser fijados previamente por el investigador. Ejemplos típicos en XGBoost son el número de árboles (`n_estimators`), la profundidad máxima de cada árbol (`max_depth`) o la tasa de aprendizaje (`learning_rate`). A diferencia de los parámetros del modelo, que se ajustan durante el entrenamiento, los hiperparámetros controlan el proceso de aprendizaje en sí mismo (Bergstra & Bengio, 2012).

La elección de los hiperparámetros tiene un impacto directo y significativo en el rendimiento del modelo. Una configuración inadecuada puede provocar underfitting (el modelo es demasiado simple y no captura los patrones de los datos) o overfitting (el modelo memoriza los datos de entrenamiento pero no generaliza a datos nuevos). La optimización de hiperparámetros es por tanto un paso crítico en cualquier proyecto de aprendizaje automático, especialmente cuando el espacio de búsqueda es amplio y el coste computacional de cada evaluación es elevado (Bergstra & Bengio, 2012).

2.4.2 Grid Search

Grid Search evalúa exhaustivamente todas las combinaciones posibles de un conjunto predefinido de valores de hiperparámetros, utilizando validación cruzada para estimar el rendimiento de cada combinación (Bergstra & Bengio, 2012). Aunque garantiza encontrar el óptimo dentro del espacio explorado, su coste computacional crece exponencialmente con el número de hiperparámetros.

2.4.3 Optimización bayesiana (Optuna)

La optimización bayesiana construye un modelo probabilístico (surrogate model) de la función objetivo y lo utiliza para seleccionar de forma inteligente los próximos puntos a evaluar, equilibrando exploración y explotación (Snoek et al., 2012). Optuna (Akiba et al., 2019) implementa el algoritmo Tree-structured Parzen Estimator (TPE), que aprende de las evaluaciones anteriores para proponer configuraciones de hiperparámetros con mayor probabilidad de mejorar el resultado.

2.5 Modelos de conjunto

Un ensemble model (o modelo de conjunto en español) es un sistema de predicción que combina múltiples modelos para obtener mejores resultados que cualquiera de ellos por separado (Dietterich, 2000).

Existen tres estrategias principales para combinar modelos en un ensemble (Dietterich, 2000):

- **Promediado** (averaging): la predicción final es la media (simple o ponderada) de las predicciones de todos los modelos. Es la estrategia más sencilla y robusta cuando los modelos tienen un rendimiento similar.
- **Apilamiento** (stacking): se entrena un meta-modelo que aprende a combinar las predicciones de los modelos base como variables de entrada. Permite capturar relaciones no lineales entre los modelos pero requiere más datos y es más propenso al sobreajuste.
- **Selección del mejor modelo por subgrupo** (model selection): se asigna a cada unidad de predicción (en este caso, cada cantón) el modelo que mejor se adapta a sus características específicas, evaluado mediante validación cruzada (Makridakis et al., 2018).

La estrategia de selección del mejor modelo por subgrupo asigna a cada unidad de predicción, en este caso, cada cantón, el modelo que mejor se adapta a sus características específicas de volumen y variabilidad.

Esta estrategia es preferible al promediado simple de modelos cuando los datos presentan alta heterogeneidad entre unidades, como ocurre en el mercado suizo donde los cantones tienen perfiles de demanda muy distintos.

2.6 Validación de modelos de series temporales

2.6.1 Importancia de la validación

La validación es el proceso mediante el cual se estima el rendimiento real de un modelo sobre datos no vistos durante el entrenamiento. Sin una validación rigurosa, existe el riesgo de seleccionar modelos que funcionan bien sobre los datos de entrenamiento pero que fallan al predecir datos nuevos, fenómeno conocido como sobreajuste (overfitting) (Tashman, 2000).

En el contexto de las series temporales, la validación presenta una dificultad adicional: el orden cronológico de los datos debe preservarse en todo momento. El uso de técnicas de validación cruzada estándar (que seleccionan subconjuntos aleatorios de los datos) no es apropiado porque implicaría usar datos futuros para predecir el pasado, introduciendo una fuga de información temporal que produciría estimaciones de rendimiento artificialmente optimistas (Tashman, 2000).

2.6.2 Validación cruzada

La validación cruzada (cross-validation) es una técnica general de evaluación que divide el conjunto de datos en k subconjuntos (folds), entrena el modelo con $k - 1$ de ellos y evalúa con el restante, repitiendo el proceso k veces y promediando los resultados (Bergstra & Bengio, 2012). El promedio de los k errores proporciona una estimación más robusta del rendimiento real del modelo que una única división entrenamiento-test, reduciendo la varianza de la estimación.

2.6.3 Validación cruzada walk-forward

La validación cruzada no es aplicable directamente a series temporales porque podría utilizar datos futuros para predecir el pasado. La validación cruzada walk-forward resuelve este problema manteniendo el orden cronológico: el conjunto de entrenamiento siempre precede temporalmente al conjunto de test (Tashman, 2000). Esto se puede ver de forma más clara en la figura inferior.

En este trabajo se emplean tres cortes temporales: diciembre 2023, junio 2024 y diciembre 2024. Estos cortes se pueden observar gráficamente en la Figura 2.1. Obteniendo el MAPE medio de los tres períodos de test como estimación robusta del error esperado en producción. Esta métrica es más conservadora pero más realista que la validación con un único corte.




Figura 2.1: Esquema de la validación walk-forward con tres cortes temporales. En cada iteración el conjunto de entrenamiento crece y el test evalúa el período inmediatamente posterior.

2.6.4 MAPE

El Error Porcentual Absoluto Medio (MAPE) se define como:

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100$$

donde y_t es el valor real e $\hat{y}_t$ el valor predicho en el período t . Su interpretación relativa facilita la comparación entre cantones de distintos volúmenes. En predicción de demanda industrial, valores inferiores al 30 % se consideran buenos y valores inferiores al 50 % se consideran aceptables (Chase, 2013).

2.7 Visualización de datos

La visualización de datos es la representación gráfica de información con el objetivo de facilitar su comprensión e interpretación (Plotly Technologies Inc., 2015). Una visualización efectiva permite identificar patrones, tendencias y anomalías que serían difíciles de detectar en tablas numéricas, y facilita la comunicación de resultados técnicos a audiencias no especializadas.

Los principales tipos de visualización utilizados en proyectos de análisis de datos son:

- **Gráficos de líneas:** ideales para representar la evolución temporal de una variable. Se utilizan en este proyecto para mostrar el histórico de ventas y las predicciones por cantón.

- **Gráficos de barras:** permiten comparar valores entre categorías. En este proyecto se usan para comparar el MAPE entre cantones y la distribución del mix de producto.
- **Mapas coropléticos y de burbujas:** representan variables sobre una base geográfica. Se utilizan para visualizar la distribución territorial de la demanda y la precisión del modelo por cantón.
- **Gráficos de dispersión:** muestran la relación entre dos variables continuas. Se emplean en el análisis de correlación entre temperatura y ventas.
- **Gráficos de sectores:** representan la distribución proporcional de una variable categórica. Se usan para mostrar la distribución de modelos en el ensemble.

En este proyecto se utilizan dos herramientas de visualización complementarias: Plotly (Plotly Technologies Inc., 2015) para la generación de gráficas interactivas en el agente conversacional, y Tableau Public (Tableau Software, LLC, 2024) para el desarrollo del panel de control empresarial interactivo con filtros globales.

2.8 Agentes conversacionales y modelos de lenguaje

Los modelos de lenguaje grandes (LLM por sus siglas en inglés) son sistemas de inteligencia artificial entrenados sobre grandes corpus de texto capaces de generar respuestas coherentes en lenguaje natural ante preguntas o instrucciones arbitrarias (Anthropic, 2024). Su aplicación como agentes conversacionales especializados en un dominio concreto se realiza mediante la técnica del system prompt: un bloque de instrucciones y contexto que se envía en cada llamada a la API junto con el historial de conversación, definiendo el rol, el conocimiento y el comportamiento del modelo.

Esta técnica permite encapsular todo el conocimiento de un proyecto, datos, resultados, criterios de interpretación, en un único prompt reutilizable, sin necesidad de reentrenar el modelo. El agente resultante puede responder preguntas específicas sobre el dominio, generar resúmenes y recomendar visualizaciones relevantes, actuando como capa de interpretación inteligente sobre herramientas de visualización como Tableau (Anthropic, 2024).

2.9 Herramientas y tecnologías

El proyecto se implementa íntegramente en Python 3.11 sobre un entorno conda. Las principales librerías utilizadas son:

- **pandas y NumPy**: manipulación y procesamiento de datos tabulares (Harris et al., 2020; McKinney, 2010).
- **scikit-learn**: pipelines de preprocesamiento, validación cruzada y modelos de regresión lineal regularizada (Pedregosa et al., 2011).
- **XGBoost**: implementación del algoritmo de gradient boosting (Chen & Guestrin, 2016).
- **statsmodels**: modelos SARIMA y SARIMAX (Seabold & Perktold, 2010).
- **GeoPandas**: operaciones geoespaciales y spatial join para la asignación cantonal (Jordahl et al., 2021).
- **Optuna**: optimización bayesiana de hiperparámetros (Akiba et al., 2019).
- **Plotly**: visualización de resultados (Plotly Technologies Inc., 2015).
- **Flask**: servidor web para el agente conversacional (Ronacher, 2010).
- **Tableau Public**: desarrollo del dashboard interactivo (Tableau Software, LLC, 2024).

3 ANÁLISIS DE LA SITUACIÓN

Este capítulo describe el punto de partida del proyecto: los datos disponibles, el contexto del mercado suizo de neumáticos y las hipótesis sobre su comportamiento. A partir de ello se definen los requisitos del sistema y se presenta la solución propuesta que sirve de hoja de ruta para el desarrollo del Capítulo 4.

3.1 Descripción detallada del problema

3.1.1 Datasets disponibles

El proyecto cuenta con cinco conjuntos de datos de cliente proporcionados por SDG Group. Por motivos de confidencialidad, el nombre del cliente y clientes del cliente no puede ser revelado en este documento. La Tabla 3.1 resume las características principales de cada dataset.

Cuadro 3.1: Resumen de los datasets disponibles para el proyecto.

Dataset	Temporal	Geográfica	Filas	Descripción
Sell In	Mensual (2023-2026)	Código postal	294.132	Ventas a distribuidores
Sell Out	Mensual (2018-2026)	Código postal	704.699	Ventas al consumidor final
Customer Master	Estático	CP + coordenadas	3.464	Tabla maestra de clientes
Carpark	Anual (2026)	Código postal	3.963.645	Parque de vehículos
Tire Potential	Mensual (2024-2026)	Código postal	5.069.750	Potencial estimado de mercado

3.1.1.1 Sell In

El dataset de Sell In recoge las transacciones realizadas entre el fabricante y sus distribuidores en el mercado suizo. Las columnas más relevantes son:

- **MONTHDATE:** fecha de la transacción con granularidad mensual. Cubre el período enero 2023 - marzo 2026.
- **SHIP_TO_CUST_ID:** identificador del punto de entrega física del pedido. Es la variable geográfica principal del dataset, ya que permite vincular cada transacción con un código postal a través del Customer Master.
- **PAYER_CUST_ID:** identificador del cliente pagador. Puede diferir del punto de entrega cuando un mismo distribuidor centraliza los pagos de varias sucursales.
- **GENERALCARTYPE:** tipo de vehículo al que está destinado el neumático (Passenger, 4x4, Light Truck).
- **TIRESEASON:** estacionalidad del neumático (Winter, Summer, All Season).
- **BRANDTIER:** segmento de marca (Premium, Quality, Budget), indicador del posicionamiento del producto.
- **QUANTITY:** volumen de neumáticos en unidades, variable objetivo del análisis de aprovisionamiento.

3.1.1.2 Sell Out

El dataset de Sell Out recoge las ventas realizadas por seis empresas distribuidoras al consumidor final. A diferencia del Sell In, este dataset refleja la demanda real del mercado. Las columnas más relevantes son:

- MONTHDATE: fecha de la transacción con granularidad mensual. Cubre el período enero 2018 - febrero 2026, ofreciendo un histórico más largo que el Sell In.
- POSTALCODE: código postal del punto de venta, que permite la asignación directa a un cantón sin necesidad de join con otras tablas.
- TIRESEASON: estacionalidad del neumático.
- BRANDTIER: segmento de marca.
- UUHPSEGMENT: subsegmento de producto (B estándar, UUHP ultra premium), complementario al BRANDTIER.
- TOTALSELLOUTQTTY: volumen de neumáticos vendidos en unidades. Es la variable objetivo del sistema de predicción.
- ISB2B: indicador booleano que distingue ventas a empresas (B2B) de ventas a particulares (B2C), relevante para el análisis del canal de distribución.

3.1.1.3 Customer Master

Tabla maestra de clientes que actúa como puente geográfico entre el Sell In y los cantones suizos. Las columnas clave son:

- CUSTOMER_ID: identificador único del cliente, vinculable con SHIP_TO_CUST_ID y PAYER_CUST_ID del Sell In.
- POSTAL_CODE: código postal de la ubicación del cliente, necesario para la asignación cantonal.
- LATITUDE y LONGITUDE: coordenadas geográficas del cliente, utilizadas en las uniones espaciales con el formato cantonal.

3.1.1.4 Carpark

Dataset con el inventario estimado del parque de vehículos suizo para 2026 a nivel de código postal. Proporciona el contexto estructural del mercado por zona geográfica. Las columnas más relevantes son:

- LOCATIONID: código de localización (prefijo CH más código postal).
- GENERALCARTYPE: distingue vehículos eléctricos (EV) de vehículos de combustión (Non-EV).
- REGISTRATIONYEAR: año de matriculación, que permite calcular la antigüedad media del parque por cantón.
- SIZETYPEID: dimensiones del neumático en formato estándar (ej. 215/60R16), que determina el segmento de producto demandado.
- TIREQQUANTITY: número estimado de neumáticos de ese tipo en el parque vehicular de la zona.
- BRANDTIER: segmento de marca esperado según el tipo de vehículo.

3.1.1.5 Tire Potential

Dataset con la estimación del potencial de mercado por código postal, canal de distribución y mes. Se utiliza como referencia para evaluar la penetración relativa de las empresas reportantes en cada cantón y como variable de contexto en el análisis geográfico.

3.1.2 Contexto y características del mercado suizo

El mercado suizo de neumáticos presenta una serie de características estructurales que condicionan tanto el análisis como el diseño del sistema de predicción:

Estacionalidad climática marcada: la geografía alpina de Suiza impone una doble temporada de neumáticos muy definida. Se espera que la demanda presente picos pronunciados en primavera (cambio a neumáticos de verano) y en otoño (cambio a neumáticos de invierno), con valles pronunciados en los meses intermedios. Esta estacionalidad bimodal debería ser el patrón dominante de cualquier modelo predictivo viable.

Desfase entre canal mayorista y minorista: se espera un desfase temporal entre el Sell In (aprovisionamiento del canal) y el Sell Out (venta al consumidor final), ya que los distribuidores se abastecen con antelación a la temporada. Este desfase, si se confirma en el análisis, permitirá utilizar el Sell In como variable predictora adelantada del Sell Out.

Heterogeneidad cantonal: los 26 cantones suizos presentan perfiles socioeconómicos, geográficos y de movilidad muy distintos. Se prevé que cantones urbanos y de alto poder adquisitivo (Zug, Basel, Zürich) presenten una mayor demanda de neumáticos premium y de mayor diámetro, mientras que cantones rurales y alpinos (Graubünden, Uri, Valais) presenten un mix distinto orientado al segmento 4x4 y todoterreno. Esta heterogeneidad hace esperar que un modelo único para todos los cantones no sea la solución óptima.

Cobertura parcial del mercado: el Sell Out solo recoge las ventas de seis empresas que voluntariamente reportan información. Se prevé que la penetración de estas empresas varíe significativamente entre cantones, lo que limitará la representatividad del análisis en algunas zonas y requerirá contextualizar los resultados con el Tire Potential.

Tendencias estructurales del parque vehicular: la electrificación creciente del parque (vehículos eléctricos e híbridos) y la tendencia hacia vehículos de mayor tamaño (SUV, 4x4) hacen prever cambios en el mix de producto demandado: mayor proporción de neumáticos de diámetro elevado y aparición de demanda específica para vehículos eléctricos (neumáticos de mayor carga y menor resistencia a la rodadura). Estas tendencias deberán tenerse en cuenta tanto en el análisis exploratorio como en la selección de variables predictoras.

Influencia del contexto macroeconómico: el precio medio del neumático en Suiza es sensible a la inflación y al poder adquisitivo del consumidor. Se prevé que variables como el índice de precios al consumo (CPI) y la inflación interanual aporten información relevante para la predicción del volumen de ventas, especialmente en períodos de alta presión inflacionaria.

3.2 Requisitos

3.2.1 Requisitos funcionales

- **RF1:** el sistema debe generar predicciones mensuales de volumen de Sell Out para los 26 cantones suizos con un horizonte mínimo de 12 meses.
- **RF2:** las predicciones deben evaluarse mediante MAPE calculado con walk-forward cross-validation de al menos tres cortes temporales, para garantizar una estimación robusta del error esperado en producción.
- **RF3:** el sistema debe gestionar la heterogeneidad de volúmenes entre cantones, aplicando modelos distintos según las características de cada zona geográfica.
- **RF4:** los resultados deben visualizarse en un panel de control interactivo con filtros por cantón y modelo, accesible para perfiles no técnicos.
- **RF5:** el sistema debe incorporar un agente conversacional capaz de responder preguntas en lenguaje natural sobre los resultados del modelo, interpretar la fiabilidad de las predicciones por cantón y recomendar visualizaciones relevantes según el contexto de la pregunta.
- **RF6:** el sistema debe incorporar variables externas (climáticas, macroeconómicas y del parque vehicular) como predictores adicionales al histórico de ventas.

3.2.2 Requisitos no funcionales

- **RNF1 - Confidencialidad:** todos los datos sensibles (nombres de empresas, clientes y marcas) deben ser anonimizados antes de cualquier análisis, con mapeos consistentes entre datasets almacenados de forma segura fuera del repositorio del proyecto.
- **RNF3 - Mantenibilidad:** el código debe estar estructurado de forma modular, con separación clara entre la capa de datos, la capa de modelado y la capa de presentación, facilitando la actualización del modelo cuando se disponga de nuevos datos.
- **RNF4 - Escalabilidad:** la arquitectura del sistema debe permitir incorporar nuevos cantones, nuevas fuentes de datos o nuevos modelos sin necesidad de rediseñar el proceso completo.
- **RNF5 - Usabilidad:** el panel de control y el agente conversacional deben ser accesibles para usuarios sin perfil técnico, con una interfaz clara e intuitiva que no requiera conocimientos de estadística o programación para su uso.
- **RNF6 - Rendimiento:** el agente conversacional debe generar respuestas en un tiempo razonable para su uso en presentaciones y demostraciones en directo, con un tiempo de respuesta inferior a 10 segundos por consulta.

3.3 Solución propuesta

La solución propuesta es un sistema de análisis y predicción en cinco fases:

1. **Preparación de datos:** pipeline de limpieza, anonimización y enriquecimiento geográfico que transforma los datos brutos en un dataframe maestro cantonal mensual listo para el modelado.
2. **Análisis exploratorio:** conjunto de visualizaciones y análisis estadísticos que caracterizan el mercado en sus dimensiones temporal, geográfica y de producto.
3. **Sistema de predicción en ensemble:** selección del modelo óptimo para cada cantón a partir de la evaluación comparativa de seis familias de modelos, XGBoost con optimización bayesiana, XGBoost con variables macroeconómicas, SARIMA, SARIMAX, ETS y Ridge, validados mediante walk-forward cross-validation.
4. **Dashboard en Tableau Public:** interfaz interactiva que integra el análisis histórico, las predicciones y la evaluación técnica del ensemble, con filtros globales por cantón y modelo.
5. **Agente conversacional:** aplicación web local desarrollada en Python con Flask que integra el panel de control de Tableau como capa de presentación empresarial y añade una capa de interpretación inteligente mediante llamadas a la API de Claude (Anthropic, 2024).

4 DESARROLLO

Este capítulo describe el proceso completo seguido para llegar a los resultados que se presentan en el Capítulo 5. Se detalla cada fase del desarrollo, incluyendo las decisiones tomadas, los pasos intermedios y los fragmentos de código más relevantes.

4.1 Preparación y limpieza de datos

4.1.1 Entorno de trabajo

Todo el desarrollo se realizó en Python 3.11 dentro de un entorno conda dedicado al proyecto, gestionado con Anaconda (Anaconda, Inc., 2020).

El trabajo se estructuró en cinco notebooks de Jupyter numerados secuencialmente: resumen inicial, EDA temporal, EDA geográfico, EDA de producto y modelado predictivo.

4.1.2 Carga y diagnóstico inicial

El primer paso fue cargar los conjuntos de datos y realizar un diagnóstico de su calidad. El diagnóstico reveló los siguientes problemas a resolver:

- **Sell In:** 51 columnas, de las que 2.802 registros (0,95 %) carecen de código postal y 1.013 registros no tienen dirección de envío (0,34 %) (SHIP_TO_CUST_ID).
- **Sell Out:** 33 columnas, con tipos de dato mixtos en columnas de texto que generaban advertencias al cargar.
- **Valores negativos:** 6.771 registros negativos en Sell In (2,3 % del volumen) y 4.409 en Sell Out (0,9 %), correspondientes a devoluciones, que se mantuvieron en el conjunto de datos al ser parte del ciclo de negocio.

4.1.3 Corrección de tipos de dato

Las columnas de coordenadas del Sell In se almacenaban como texto con coma decimal en lugar de punto, lo que requería conversión explícita antes de cualquier operación geográfica:

```
1 df_si['MONTH_DT'] = pd.to_datetime(df_si['MONTH_DT'])
2 df_si['CUSTOMERLATITUDE'] = (
3     df_si['CUSTOMERLATITUDE']
4     .str.replace(',', '.')
5     .astype(float)
6 )
7 df_si['CUSTOMERPOSTALCODE'] = (
8     df_si['CUSTOMERPOSTALCODE']
9     .dropna().astype(int)
10 )
```

Listing 4.1: Corrección de tipos de dato en columnas geográficas.

4.1.4 Anonimización de datos sensibles

Dado que los datos contienen información confidencial de empresas y clientes, se diseñó un proceso de anonimización con mapeos consistentes entre conjuntos de datos. Las 17 columnas sensibles identificadas (11 en Sell In, 6 en Sell Out) fueron sustituidas por identificadores genéricos:

- Las seis empresas presentes en ambos datasets (Sell In y Sell Out) se codificaron como Empresa_1 a Empresa_6, manteniendo la misma clave en los dos ficheros para que las referencias cruzadas entre ellos sigan siendo válidas.
- El resto de empresas que solo aparecen en el Sell In, distribuidores intermedios sin presencia en el Sell Out, se codificaron a partir de Empresa_7.
- Algunas empresas del Sell In aparecen con variantes en el nombre que identifican filiales o delegaciones (por ejemplo, sufijos _A o _B). Estas variantes se mantuvieron como tales en lugar de unificarlas, ya que los sufijos tienen significado real y su eliminación podría ocultar diferencias geográficas o comerciales relevantes.

Durante el proceso se identificaron falsos positivos en el emparejamiento por nombre que requirieron revisión manual. Por ejemplo, la cadena de búsqueda SAG generaba coincidencias con entidades que contenían SAGL en su nombre, que es una forma jurídica suiza (*Società a garanzia limitata*) sin relación con la empresa buscada. Los diccionarios de mapeo se almacenaron en ficheros JSON externos al repositorio.

4.1.5 Enriquecimiento geográfico

El enriquecimiento geográfico es un paso crítico del proyecto ya que ninguno de los conjuntos de datos originales contiene la variable cantón. Sin esta asignación no sería posible agregar los datos a nivel cantonal ni construir el sistema de predicción por zona geográfica.

4.1.5.1 Asignación de cantón al Sell Out

El Sell Out contiene la columna POSTALCODE directamente, con un 99,6 % de cobertura, por lo que la asignación cantonal fue directa mediante la fusión con la tabla de correspondencias código postal - cantón.

4.1.5.2 Asignación de cantón al Sell In

El Sell In no contiene código postal, por lo que no es posible asignar directamente un cantón a cada transacción. Para resolverlo se utilizó el Customer Master como tabla puente: esta tabla contiene la dirección física de cada cliente identificado por un código único. Cruzando ese código con el campo SHIP_TO_CUST_ID del Sell In, que identifica el punto de entrega de cada pedido, se obtuvo el código postal asociado a cada transacción y, a partir de él, el cantón correspondiente.

Cuando la dirección de envío no estaba disponible se aplicó un proceso de respaldo utilizando el código del cliente pagador (PAYER_CUST_ID), que en la mayoría de los casos corresponde a la misma ubicación geográfica. Este proceso en dos pasos permitió recuperar la cobertura geográfica del 87,7 % inicial hasta el 99,0 % de los registros y el 99,4 % del volumen.

```

1 # Unión principal: dirección de envío
2 df_si = df_si.merge(
3     df_cm[['CUSTOMERID', 'CUSTOMERPOSTALCODE',
4           'CUSTOMERLATITUDE', 'CUSTOMERLONGITUDE']],
5     left_on='SHIP_TO_CUST_ID',
6     right_on='CUSTOMERID',
7     how='left'
8 )
9 # Fallback: pagador (cuando no hay dirección de envío)
10 mask = df_si['CUSTOMERPOSTALCODE'].isnull()
11 df_si.loc[mask] = df_si.loc[mask].merge(
12     df_cm[['CUSTOMERID', 'CUSTOMERPOSTALCODE']],
13     left_on='PAYER_CUST_ID',
14     right_on='CUSTOMERID',
15     how='left'
16 )

```

Listing 4.2: Unión del Sell In con Customer Master para obtener código postal.

La cobertura inicial por SHIP_TO_CUST_ID fue del 87,7 %. El fallback con PAYER_CUST_ID recuperó 33.412 registros adicionales, elevando la cobertura final al 99,0 % de registros y el 99,4 % del volumen.

4.1.5.3 Unión espacial para asignación cantonal

Para asignar cada código postal a su cantón se utilizaron dos fuentes de información: las coordenadas geográficas (latitud y longitud) de cada código postal, obtenidas del Customer Master, y el mapa oficial de los límites territoriales de los 26 cantones suizos, descargado de GADM 4.1 (GADM, 2022). GADM es una base de datos pública que proporciona los contornos geográficos de las divisiones administrativas de todos los países del mundo en formato vectorial, es decir, como polígonos que delimitan exactamente el territorio de cada cantón.

La asignación consistió en determinar, para cada código postal, dentro de qué polígono cantonal se encontraban sus coordenadas. Esta operación se denomina unión espacial y requiere herramientas capaces de trabajar con geometrías geográficas, algo que pandas convencional no soporta. Para ello se utilizó GeoPandas (Jordahl et al., 2021), una extensión de pandas que añade soporte para datos geoespaciales y permite realizar este tipo de cruce entre puntos y polígonos de forma eficiente. El resultado fue la asignación correcta de 1.165 de 1.176 códigos postales únicos (99,1 %).


```

1 url = "https://geodata.ucdavis.edu/gadm/gadm4.1/json/
2     gadm41_CHE_1.json"
3 cantons = gpd.read_file(io.BytesIO(
4     requests.get(url).content))
5
6 # Crear GeoDataFrame con coordenadas de cada CP
7 cp_coords_geo['geometry'] = cp_coords_geo.apply(
8     lambda row: Point(row['lon'], row['lat']), axis=1)
9 cp_gdf = gpd.GeoDataFrame(
10     cp_coords_geo, geometry='geometry', crs='EPSG:4326')
11
12 # Unión espacial CP -> cantón
13 cp_canton = gpd.sjoin(
14     cp_gdf,
15     cantons[['NAME_1', 'geometry']],
16     how='left', predicate='within'
17 )

```

Listing 4.3: Spatial join para asignación de cantón a cada código postal.

4.2 Análisis Exploratorio de Datos

El análisis exploratorio de datos es el proceso de examinar los datos disponibles antes de modelarlos, con el objetivo de comprender su estructura, identificar patrones relevantes y detectar anomalías que puedan afectar al modelado posterior. En este proyecto el EDA se divide en tres dimensiones: temporal, geográfica y de producto, cada una orientada a responder preguntas distintas sobre el mercado suizo de neumáticos.

4.2.1 Proceso de análisis temporal

El análisis temporal estudia cómo evoluciona la demanda a lo largo del tiempo. En este proyecto es especialmente relevante porque la estacionalidad es el patrón dominante del mercado suizo y su correcta caracterización es la base sobre la que se construirán las variables predictoras del modelo.

4.2.1.1 Construcción de series temporales agregadas

El primer paso del análisis temporal fue agregar los datos a nivel mensual para obtener series comparables entre Sell In y Sell Out, como se puede ver en la Figura 4.1.




Figura 4.1: Volumen mensual en unidades de Sell In (azul) y Sell Out (verde) en Suiza (2023-2026). Se aprecian el patrón bimodal estacional y el desfase de aproximadamente dos meses entre el aprovisionamiento del canal y la venta al consumidor final.

La visualización de ambas series puso de manifiesto la estacionalidad bimodal y el desfase entre canales, hipótesis planteadas en el Capítulo 3.

4.2.1.2 Análisis de correlación con temperatura

Para confirmar la relación entre temperatura y demanda se obtuvo la serie climática mensual de Zúrich mediante la API de Open-Meteo (Open-Meteo, 2022) y se calcularon correlaciones de Pearson con distintos desfases temporales, esto se puede ver en la Figura 4.2




Figura 4.2: Correlación entre ventas y temperatura con retardo de 2 meses para el tipo de neumáticos Winter (izquierda) y Summer (derecha).

Los diagramas muestran que cuando hace frío dos meses antes, las ventas de neumáticos tipo Summer suben y las de neumáticos tipo Winter bajan, y viceversa. Esta relación se cuantifica mediante el coeficiente de correlación ($r = 0,535$ Winter, $r = -0,446$ Summer), justificando que `temp_lag2` sea variable predictora en el feature engineering.

4.2.1.3 Análisis de la diferencia Sell In - Sell Out

Para cuantificar el desfase logístico entre canal mayorista y minorista se calculó la diferencia mensual en el período con datos comunes (2023-2026), esto se puede observar en la Figura 4.3:




Figura 4.3: Estacionalidad normalizada del Sell Out por año (2022-2025). Los cuatro años muestran un patrón prácticamente idéntico.

El análisis reveló una diferencia media del 24,1 % entre el volumen de Sell In y el de Sell Out en el mismo mes, confirmando la hipótesis del aprovisionamiento anticipado: los distribuidores reciben y almacenan los neumáticos semanas antes de que el consumidor final los compre, por lo que el Sell In adelanta al Sell Out en aproximadamente dos meses. Los detalles completos se presentan en el Capítulo 5.

4.2.2 Proceso de análisis geográfico

El análisis geográfico estudia cómo se distribuye la demanda en el territorio suizo. En este proyecto es clave porque el objetivo final es predecir por cantón, por lo que entender qué zonas concentran el volumen, cuáles tienen mayor potencial de crecimiento y qué anomalías geográficas existen es indispensable antes de construir cualquier modelo.

4.2.2.1 Análisis de concentración por código postal

Se construyeron curvas de concentración, como se puede ver en la Figura 4.4 para cuantificar cómo se distribuye el volumen entre códigos postales:




Figura 4.4: Concentración de volumen en Sell-In y Sell-Out

El resultado mostró que 113 códigos postales (14 % del total) concentran el 80 % del volumen de Sell In, y 287 (12 %) el de Sell Out.

4.2.2.2 Identificación del outlier logístico

Al calcular el volumen por código postal se detectó que el CP 4624 (Härkingen, Solothurn) era extremadamente dominante en el Sell Out:

```
1 print("Volumen CP 4624:",
2       so_map[so_map['CUSTOMERPOSTALCODE'] == 4624]['volumen']
3       .values)
4 pct = (so_map[so_map['CUSTOMERPOSTALCODE'] == 4624]
5        ['volumen'].sum() / so_cp.sum() * 100)
6 print(f"% sobre total: {pct:.1f}%")
```

Listing 4.4: Identificación del outlier logístico CP 4624.

La salida confirmó que el CP 4624 concentraba el 17,2 % de todo el volumen del Sell Out, correspondiente al centro logístico de una de las empresas reportantes. Este hallazgo obligó a tratar dicho cantón de forma especial en todas las visualizaciones geográficas.

4.2.2.3 Construcción del mapa de calor

La Figura 4.5 muestra el resultado del análisis de penetración por cantón, donde se identifican claramente las zonas de oportunidad comercial.




Figura 4.5: Diferencia normalizada entre Sell Out y Tire Potential por cantón (sin Solothurn, 2024-2026). La métrica indica cuánto se aleja el volumen real del potencial estimado del mercado: verde = Sell Out por debajo del potencial (oportunidad de crecimiento), rojo = Sell Out por encima (alta penetración).

4.2.2.4 Análisis de penetración vs Tire Potential

Para identificar zonas de oportunidad se calculó la diferencia normalizada entre el Sell Out y el Tire Potential por cantón, restringida al período común (2024-2026) como se puede ver en la Figura 4.6:




Figura 4.6: Cantones que están por debajo del 100 % presentan una oportunidad de mercado, mientras las que están por encima están suficientemente abastecidos

4.2.3 Proceso de análisis de producto

El análisis de producto estudia qué tipos de neumáticos se venden y cómo evoluciona su mix a lo largo del tiempo. En este proyecto permite identificar tendencias estructurales del mercado suizo, como la premiumización o la migración hacia llantas de mayor diámetro, que pueden incorporarse como variables predictoras o como contexto para interpretar los resultados del modelo.

4.2.3.1 Exploración de columnas de producto

La Figura 4.7 muestra la evolución de la proporción de categoría de marca a lo largo del período analizado, donde se aprecia claramente el proceso de premiumización del mercado suizo.




Figura 4.7: Evolución del mix de tier de marca por año (2018-2026). Premium pasa del 28 % al 80 % en el período analizado.

4.2.3.2 Análisis de la anomalía de mayo 2025

Durante el análisis de la mezcla por tipo de vehículo se detectó una anomalía en mayo 2025, donde el segmento 4x4 alcanzó el 41 % de la mezcla (frente al 22,5 % habitual). Como se puede ver en la Figura 4.8:




Figura 4.8: Evolución temporal por tipo de vehículo

Se realizó un pedido extraordinario de 5.330 unidades de 4x4 en ese mes, lo que explicaba la anomalía.

4.2.3.3 Distribución del diámetro de llanta (RIM)

La Figura 4.9 ilustra la migración hacia llantas de mayor diámetro, tendencia estructural que tiene implicaciones directas en el mix de producto demandado por cantón.




Figura 4.9: Distribución de diámetro de llanta (RIM) y evolución del mix por año (2019-2026).

4.3 Modelado predictivo

El objetivo del modelado es predecir el volumen mensual de Sell Out, es decir, la venta al consumidor final, por cantón para un horizonte de 12 meses. Para ello se utiliza el histórico de Sell Out como variable principal, enriquecido con el Sell In como señal adelantada, variables climáticas y variables macroeconómicas y del parque vehicular por cantón.

4.3.1 Construcción del dataframe maestro

El punto de partida del modelado fue la construcción de una tabla maestra con granularidad cantón-mes que integra Sell Out, Sell In y datos climáticos. Dado que el Sell In solo está disponible desde 2023, los registros anteriores a esa fecha carecen de esa variable y dependen exclusivamente del histórico de Sell Out y las variables climáticas:

```
1 so_canton_mes = df_so.groupby(  
2     ['CANTON', 'MONTHDATE'])['TOTALSELLOUTQTTY']  
3     .sum().reset_index()  
4 so_canton_mes.columns = ['canton', 'fecha', 'sell_out']  
5  
6 df_master = so_canton_mes.merge(  
7     si_canton_mes, on=['canton', 'fecha'], how='left'  
8 ).merge(df_clima, on='fecha', how='left')  
9  
10 print('Shape master:', df_master.shape)  
11 # Shape master: (2436, 7)
```

Listing 4.5: Construcción del dataframe maestro cantón-mes.

4.3.2 Feature engineering

El feature engineering es el proceso de construir las variables de entrada del modelo a partir de los datos disponibles. En series temporales es un paso crítico porque los modelos de aprendizaje automático no tienen noción del tiempo por sí solos. El proceso fue iterativo: se construyó un primer conjunto de variables base (v1) y posteriormente se enriqueció con variables macroeconómicas y del parque vehicular (v2), mejorando el rendimiento del modelo en cada iteración.

4.3.2.1 Features v1 — Base temporal y climática

Se construyeron 15 variables predictoras combinando tres tipos de información: variables temporales (mes, trimestre y su codificación cíclica) para capturar la estacionalidad, retardos y medias móviles del Sell Out (lag 1, 2, 3, 6 y 12 meses) para capturar la inercia de la demanda, y variables climáticas con retardo de 2 meses (temperatura, nieve y precipitación) para capturar el efecto del clima sobre la demanda estacional.

```
1 # Variables temporales
2 df_master['mes'] = df_master['fecha'].dt.month
3 df_master['año'] = df_master['fecha'].dt.year
4 df_master['trimestre'] = df_master['fecha'].dt.quarter
5 # Codificación cíclica del mes
6 df_master['mes_sin'] = np.sin(
7     2 * np.pi * df_master['mes'] / 12)
8 df_master['mes_cos'] = np.cos(
9     2 * np.pi * df_master['mes'] / 12)
10 # Lags del Sell Out
11 for lag in [1, 2, 3, 6, 12]:
12     df_master[f'sell_out_lag{lag}'] = (
13         df_master.groupby('canton')['sell_out']
14         .shift(lag))
15 # Rolling windows
16 df_master['sell_out_rol13'] = (
17     df_master.groupby('canton')['sell_out']
18     .transform(lambda x: x.shift(1).rolling(3).mean()))
19 df_master['sell_out_rol16'] = (
20     df_master.groupby('canton')['sell_out']
21     .transform(lambda x: x.shift(1).rolling(6).mean()))
22 # Variables climáticas con lag de 2 meses
23 df_master['temp_lag2'] = df_master['temp_media'].shift(2)
24 df_master['nieve_lag2'] = df_master['nieve'].shift(2)
```

Listing 4.6: Feature engineering — variables base (v1).

4.3.2.2 Features v2 — Enriquecimiento macroeconómico

En una segunda iteración se añadieron 7 variables adicionales procedentes del CPI suizo (World Bank, 2023) y del dataset Carpark:

```
1 # CPI suizo mensual (interpolado de anual a mensual)
2 url_cpi = "https://api.worldbank.org/v2/country/CH/
3     indicator/FP.CPI.TOTL?format=json&date=2018:2026"
4 df_cpi = pd.DataFrame(...)] # procesado de la API
5
6 # Variables del Carpark por cantón
7 cp_features = df_cp.groupby('CANTON').agg(
8     total_vehiculos=('TIREQQUANTITY', 'sum'),
9     pct_ev=('GENERALCARTYPE',
10         lambda x: (x == 'EV').mean() * 100),
11     antiguedad_media=('REGISTRATIONYEAR',
12         lambda x: 2026 - x.mean()),
13     pct_premium=('BRANDTIER',
14         lambda x: (x == 'Premium').mean() * 100),
15     pct_winter=('TIRESEASONALITY',
16         lambda x: (x == 'Winter').mean() * 100)
17 )
18
19 # Merge con el dataframe maestro
20 df_master_v2 = df_master.merge(
21     df_cpi_mensual[['fecha', 'cpi', 'inflacion_yoy']],
22     on='fecha', how='left'
23 ).merge(cp_features, left_on='canton',
24     right_on='CANTON', how='left')
```

Listing 4.7: Integración de variables macroeconómicas y del parque vehicular.

4.3.3 Partición train-test

Se definió una única partición temporal con corte en diciembre de 2024, reservando los 14 meses siguientes (enero 2025 - febrero 2026) como conjunto de test. Así se cubre un ciclo estacional completo y se evalúa sobre los dos picos de demanda anuales y no solo en una parte del patrón estacional:

```
1 fecha_corte = '2024-12-01'
2 df_train = df_master[
3     df_master['fecha'] <= fecha_corte].copy()
4 df_test = df_master[
5     df_master['fecha'] > fecha_corte].copy()
6
7 print('Train:', df_train.shape,
8     '| Rango:',
9     df_train['fecha'].min(), '->',
10    df_train['fecha'].max())
11 print('Test:', df_test.shape,
12     '| Rango:',
13     df_test['fecha'].min(), '->',
14    df_test['fecha'].max())
```

Listing 4.8: Partición train-test con corte temporal en diciembre 2024.

La función MAPE utilizada en todo el proceso ignora los valores nulos y los ceros para evitar divisiones por cero:

```
1 def mape(y_true, y_pred):
2     mask = y_true != 0
3     return np.mean(
4         np.abs((y_true[mask] - y_pred[mask])
5                / y_true[mask])) * 100
```

Listing 4.9: Función MAPE utilizada en la evaluación de modelos.

4.3.4 Bases

Se establecieron dos modelos de referencia antes de entrenar cualquier modelo complejo:

```
1 # Naive: predice el valor del mes anterior
2 df_test['pred_naive'] = df_test['sell_out_lag1']
3
4 # Media histórica por cantón y mes
5 media_canton_mes = df_train.groupby(
6     ['canton', 'mes'])['sell_out'].mean().reset_index()
7 df_test = df_test.merge(media_canton_mes,
8     on=['canton', 'mes'], suffixes=('', '_media'))
9
10 mae_naive = mean_absolute_error(
11     df_test['sell_out'], df_test['pred_naive'])
12 mape_naive = mape(
13     df_test['sell_out'].values,
14     df_test['pred_naive'].values)
```

Listing 4.10: Evaluación de los modelos Base.

Obteniendo para el Naive un MAPE del 66.4% y para la Media histórica un MAPE del 50,9%.

4.3.5 XGBoost global — Primera iteración

El primer modelo real fue XGBoost entrenado con todos los cantones simultáneamente:

```
1 features = ['mes', 'año', 'trimestre', 'mes_sin', 'mes_cos',
2             'sell_out_lag1', 'sell_out_lag2', 'sell_out_lag3',
3             'sell_out_lag6', 'sell_out_lag12', 'sell_out_roll3',
4             'sell_out_roll6', 'temp_lag2', 'nieve_lag2', 'precipitacion']
5
6 xgb = XGBRegressor(n_estimators=300,
7     learning_rate=0.05, max_depth=4,
8     subsample=0.8, colsample_bytree=0.8,
9     random_state=42)
10 xgb.fit(X_train, y_train)
11 y_pred = xgb.predict(X_test)
```

Listing 4.11: XGBoost global — primera iteración.

El MAPE del 92,5% (cuanto más alto peor) siendo peor que los bases reveló el problema: el modelo global penalizaba los cantones pequeños donde el error relativo era enorme, como se observa en la Tabla 4.1.

Cuadro 4.1: MAPE del XGBoost global por cantón (selección). El modelo falla especialmente en cantones de bajo volumen.

Cantón	Volumen medio (uds/mes)	MAPE
AppenzellAusserrhoden	58	750,1 %
AppenzellInnerrhoden	3	292,4 %
Obwalden	86	215,9 %
Zug	688	101,5 %
Zürich	3.821	29,1 %
Bern	2.071	19,5 %

El modelo daba mejores resultados en cantones con mayor volumen, esto motivó la estratificación de cantones.

4.3.6 Estratificación de cantones

Se calculó el volumen medio mensual por cantón en el período 2023-2026, más representativo que el período completo, dado que el Sell Out de 2018-2021 tenía menor cobertura de puntos de venta. De esta forma se dividen los cantones en dos grupos, grandes y pequeños, compuestos por 13 cantones cada uno.

```

1 volumen_reciente = df_train[
2     df_train['fecha'] >= '2023-01-01'
3 ].groupby('canton')['sell_out'].mean()
4
5 cantones_grandes = volumen_reciente[
6     volumen_reciente >= 500].index.tolist()
7 cantones_pequeños = volumen_reciente[
8     volumen_reciente < 500].index.tolist()

```

Listing 4.12: Estratificación de cantones por volumen medio mensual.

4.3.7 XGBoost v1 en cantones grandes y Grid Search

Reentrenado solo con los 13 cantones grandes, el MAPE bajó al 38,8 %. Para intentar mejorarlo se realizó una búsqueda exhaustiva de hiperparámetros con GridSearchCV y TimeSeriesSplit con 3 pliegues temporales, siendo los pliegues, o años de entrenamiento, en 2022, 2023 y 2024:

```

1 tscv = TimeSeriesSplit(n_splits=3)
2 param_grid = {
3     'n_estimators': [200, 300, 500],
4     'max_depth': [3, 4, 5],
5     'learning_rate': [0.03, 0.05, 0.1],
6     'subsample': [0.7, 0.8],
7 }
8 grid_search = GridSearchCV(
9     XGBRegressor(random_state=42, colsample_bytree=0.8),
10    param_grid, cv=tscv,
11    scoring='neg_mean_absolute_error',
12    n_jobs=-1, verbose=1)
13 grid_search.fit(X_train_g, y_train_g)

```

Listing 4.13: Grid Search con TimeSeriesSplit para XGBoost.

El Grid Search evaluó 54 combinaciones sin mejorar significativamente el resultado (39,0 % vs 38,8 %), lo que indicó que el límite del modelo con las features v1 estaba en torno al 39 % y que se necesitaban más variables predictoras.

4.3.8 SARIMA por cantón

En paralelo se entrenó SARIMA(1,1,1)(1,1,1)₁₂ individualmente por cantón, donde (1,1,1) indica un término autorregresivo, una diferenciación y un término de media móvil en el componente no estacional, y (1,1,1)₁₂ los mismos órdenes en el componente estacional con período anual de 12 meses. Esta configuración es el estándar habitual para series mensuales con estacionalidad anual:

```

1 for canton in cantones_grandes:
2     df_c = df_master[df_master['canton'] == canton][
3         ['fecha', 'sell_out']].set_index('fecha')
4     train_c = df_c[df_c.index <= '2024-12-01']
5     test_c = df_c[df_c.index > '2024-12-01']
6     model = SARIMAX(train_c['sell_out'],
7                     order=(1, 1, 1),
8                     seasonal_order=(1, 1, 1, 12),
9                     enforce_stationarity=False,
10                    enforce_invertibility=False)
11    result = model.fit(dispatch=False)
12    pred = result.forecast(steps=len(test_c))
13    mape_c = mape(test_c['sell_out'].values, pred.values)

```

Listing 4.14: Entrenamiento de SARIMA por cantón.

Los resultados por cantón se comparan con XGBoost v1 en la Tabla 4.2:

Cuadro 4.2: Comparativa SARIMA vs XGBoost v1 en cantones grandes. El ganador por cantón queda resaltado.

Cantón	MAPE SARIMA	MAPE XGB v1	Ganador
Aargau	13,9 %	19,8 %	SARIMA
Zürich	21,8 %	23,9 %	SARIMA
Ticino	23,2 %	19,3 %	XGBoost
Genève	23,4 %	71,6 %	SARIMA
Bern	27,1 %	19,5 %	XGBoost
Vaud	27,6 %	30,3 %	SARIMA
Lucerne	32,5 %	38,9 %	SARIMA
SanktGallen	36,8 %	31,0 %	XGBoost
Solothurn	40,2 %	33,4 %	XGBoost
Fribourg	41,1 %	22,4 %	XGBoost
Graubünden	46,4 %	47,3 %	SARIMA
Valais	50,8 %	43,6 %	XGBoost
Zug	163,9 %	103,7 %	XGBoost

4.3.9 Conjunto de modelos v1

Con los tres modelos evaluados (XGBoost v1, SARIMA y ETS) se construyó el primer conjunto de modelos seleccionando el modelo con menor MAPE para cada cantón, siendo el MAPE medio del conjunto de modelos del 37.2 %

```
1 ensemble = []
2 for _, row in comp_grandes.iterrows():
3     mejor = row['mejor']
4     mape_mejor = row[f'mape_{mejor}']
5     ensemble.append({
6         'canton': row['canton'],
7         'grupo': 'grande',
8         'modelo': mejor.upper(),
9         'mape': mape_mejor
10    })
11 df_ensemble = pd.DataFrame(ensemble)
```

Listing 4.15: Construcción del primer ensemble.

4.3.10 XGBoost v2 con variables macroeconómicas

Para superar el límite del 39 % se incorporaron 7 variables adicionales al modelo: el índice de precios al consumo (CPI), la inflación interanual, y cinco variables del parque vehicular por cantón (total de vehículos, porcentaje de eléctricos, antigüedad media, porcentaje premium y porcentaje de invierno). La justificación es que estas variables capturan el contexto estructural de cada cantón, su tamaño de mercado y el perfil de sus conductores, información que el histórico de ventas por sí solo no recoge. El detalle completo de todas las variables utilizadas se recoge en el Anexo C. El resultado fue un MAPE del 32,6 %, una mejora del 16 % sobre la versión anterior.

```
1 features_v2 = features + ['cpi', 'inflacion_yoy',
2     'total_vehiculos', 'pct_ev', 'antiguedad_media',
3     'pct_premium', 'pct_winter']
4
5 xgb_v2 = XGBRegressor(learning_rate=0.03,
6     max_depth=3, n_estimators=500,
7     subsample=0.8, colsample_bytree=0.8,
8     random_state=42)
9 xgb_v2.fit(X_train_v2, y_train_v2)
10 y_pred_v2 = xgb_v2.predict(X_test_v2)
```

Listing 4.16: Entrenamiento y evaluación de XGBoost v2.

4.3.11 Evaluación de SARIMAX

Se probó SARIMAX (SARIMA con variables exógenas) para los cantones donde SARIMA lideraba, con los resultados de la Tabla 4.3:

La conclusión fue que SARIMAX solo se adoptó para Vaud, donde la mejora es significativa. En el resto de cantones, las variables externas introducen ruido en lugar de señal.

Cuadro 4.3: Comparativa SARIMA vs SARIMAX. Solo Vaud mejora con la incorporación de variables exógenas.

Cantón	SARIMA	SARIMAX	Mejora	Decisión
Aargau	13,9 %	17,9 %	+4,0 pp	Mantener SARIMA
Thurgau	27,1 %	43,5 %	+16,4 pp	Mantener SARIMA
Genève	23,4 %	23,2 %	−0,2 pp	Mantener SARIMA
Vaud	27,6 %	20,6 %	−7,0 pp	Adoptar SARIMAX

4.3.12 Optimización bayesiana con Optuna

Para superar los límites del Grid Search se implementó optimización bayesiana con Optuna (Akiba et al., 2019):

```

1 def objective(trial):
2     params = {
3         'n_estimators': trial.suggest_int(
4             'n_estimators', 100, 600),
5         'max_depth': trial.suggest_int(
6             'max_depth', 2, 6),
7         'learning_rate': trial.suggest_float(
8             'learning_rate', 0.01, 0.15, log=True),
9         'subsample': trial.suggest_float(
10            'subsample', 0.6, 1.0),
11         'colsample_bytree': trial.suggest_float(
12            'colsample_bytree', 0.6, 1.0),
13         'min_child_weight': trial.suggest_int(
14            'min_child_weight', 1, 10),
15     }
16     model = XGBRegressor(**params, random_state=42)
17     model.fit(X_train_g, y_train_g)
18     pred = model.predict(X_test_g)
19     return mape(y_test_g.values, pred)
20
21 study = optuna.create_study(direction='minimize')
22 study.optimize(objective, n_trials=100,
23               show_progress_bar=True)

```

Listing 4.17: Optimización bayesiana con Optuna (100 iteraciones).

La comparativa de los tres enfoques de optimización se muestra en la Tabla 4.4:

Cuadro 4.4: Evolución del MAPE de XGBoost a lo largo del proceso de optimización de hiperparámetros.

Versión	MAPE	Observación
XGBoost v1 (parámetros iniciales)	38,8 %	Referencia
Grid Search (54 combinaciones)	39,0 %	Sin mejora
XGBoost v2 (features macro)	32,6 %	−16 %
XGBoost Bayes (Optuna, 100 it.)	29,3 %	−25 % vs GridSearch

4.3.13 Validación Cruzada Walk-forward

Para obtener una estimación robusta del error, se implementó validación cruzada walk-forward con tres cortes temporales, tal como se ilustra en la Figura 4.10:

```
1 cortes = ['2023-12-01', '2024-06-01', '2024-12-01']
2 test_periodos = [
3     ('2024-01-01', '2024-06-01'),
4     ('2024-07-01', '2024-12-01'),
5     ('2025-01-01', '2026-02-01'),
6 ]
7 mapes_cortes = []
8 for corte, (test_ini, test_fin) in zip(
9     cortes, test_periodos):
10     train = df_c[df_c.index <= corte]
11     test = df_c[(df_c.index > corte) &
12                (df_c.index <= test_fin)]
13     # Entrenar y evaluar modelo
14     model.fit(train[features], train['sell_out'])
15     pred = model.predict(test[features])
16     mapes_cortes.append(
17         mape(test['sell_out'].values, pred))
18
19 mape_wf = np.mean(mapes_cortes)
20 mape_std = np.std(mapes_cortes)
```

Listing 4.18: Validación cruzada walk-forward con tres cortes temporales.




Figura 4.10: Esquema de la validación cruzada walk-forward con tres cortes temporales aplicada en el proyecto.

4.3.14 Ensemble definitivo

Tras evaluar todas las combinaciones posibles (véase la Tabla 4.5), se construyó el ensemble definitivo asignando a cada cantón el modelo con menor MAPE *walk-forward*:

Los resultados del ensemble definitivo se presentan en el Capítulo 5, donde se incluyen las predicciones a 12 meses y la evaluación final del sistema.

Cuadro 4.5: Comprobaciones realizadas antes de cerrar el ensemble definitivo.

Comprobación	MAPE A	MAPE B	Decisión
XGB Bayes vs SARIMA (Aargau)	12,5 %	13,9 %	XGB_Bayes
XGB Bayes vs SARIMA (Genève)	44,8 %	23,4 %	SARIMA
SARIMAX vs SARIMA (Vaud)	20,6 %	27,6 %	SARIMAX
Ridge v2 vs Ridge v1 (AI)	74,7 %	49,3 %	Ridge v1
XGB v2 cantones pequeños	gana 8/13	—	XGB_v2

4.4 Panel de control en Tableau Public

4.4.1 Preparación de los CSVs para Tableau

Antes de construir el panel de control se generaron tres ficheros CSV optimizados para Tableau, cada uno con una granularidad específica:

```

1 # CSV 01: Series temporales históricas + predicciones
2 df_tableau_series.to_csv(
3     'tableau_01_series_canton.csv',
4     index=False, encoding='utf-8-sig', decimal=',')
5
6 # CSV 02: Resumen por cantón (para mapas y KPIs)
7 df_tableau_canton.to_csv(
8     'tableau_02_resumen_canton.csv',
9     index=False, encoding='utf-8-sig',
10    sep=';', decimal=',')
11
12 # CSV 03: EDA producto (brandtier, tireseason, segmento)
13 df_tableau_producto.to_csv(
14     'tableau_03_producto.csv',
15     index=False, encoding='utf-8-sig')
```

Listing 4.19: Exportación de CSVs para Tableau con formato de decimal correcto.

4.4.2 Construcción de las vistas

Se construyeron cinco hojas en Tableau (Tableau Software, LLC, 2024), cada una usando la fuente de datos más adecuada. Estas vistas se pueden ver en las siguientes Figuras 4.11, 4.12, 4.13, 4.14 y 4.15 respectivamente




Figura 4.11: Vista Serie_Temporal del panel de control de Tableau Public. Muestra el histórico de Sell Out (azul) y las predicciones (naranja) por cantón, con línea de referencia vertical marcando el inicio del período de predicción (marzo 2026).




Figura 4.12: Vista Mapa_Prediccion del panel de control de Tableau Public. Círculos proporcionales a la predicción de demanda a 12 meses posicionados sobre el mapa de Suiza. La descripción muestra cantón, predicción, modelo asignado y MAPE.



Figura 4.13: Vista Mix_Producto del panel de control de Tableau Public. Barras apiladas al 100 % mostrando la evolución del mix de tier de marca (Premium, Quality, Budget) por año, filtrable por cantón.




Figura 4.14: Vista Estacionalidad_Tipo del panel de control de Tableau Public. Curvas de demanda relativa por tipo de neumático (Winter, Summer, All Season) según el mes del año.




Figura 4.15: Vista Modelos_MAPE del panel de control de Tableau Public. Barras horizontales del MAPE walk-forward por cantón, coloreadas por modelo asignado. La línea discontinua marca el umbral de aceptabilidad del 50 %.

4.4.3 Implementación de filtros globales

Un reto técnico del panel de control fue la sincronización de filtros entre vistas que usan distintas fuentes de datos. La solución adoptada fue el uso de parámetros de Tableau en lugar de filtros nativos:

1. Se creó un parámetro `Seleccionar Canton` de tipo String con la lista de los 26 cantones más el valor "Todos".
2. En cada hoja se creó un campo calculado `Filtro Canton: [Canton] = [Seleccionar Canton] OR [Seleccionar Canton] = "Todos"`
3. El campo calculado se añadió al panel *Filters* marcando el valor *True*.

Al ser un parámetro global, actúa simultáneamente sobre todas las hojas independientemente de su fuente de datos, resolviendo la limitación de los filtros nativos de Tableau.

4.5 Agente conversacional

4.5.1 Arquitectura del sistema

El agente conversacional sigue una arquitectura cliente-servidor con tres capas bien diferenciadas:

- **Capa de presentación (frontend):** interfaz web desarrollada en HTML, CSS y JavaScript, servida por Flask. Presenta dos paneles principales: el chat a la izquierda y el panel de visualización a la derecha, que a su vez tiene dos pestañas, el panel de control de Tableau (Tableau Software, LLC, 2024) y las gráficas de análisis generadas por el agente.
- **Capa de aplicación (backend):** servidor Flask (Ronacher, 2010) que gestiona el historial de conversación, realiza las llamadas a la API de Anthropic (Anthropic, 2024) y genera las gráficas con Plotly (Plotly Technologies Inc., 2015). Expone tres endpoints principales: `/chat` para el procesamiento de mensajes, `/grafica/<nombre>` para la generación bajo demanda de visualizaciones y `/reset` para reiniciar el historial de sesión.
- **Capa de inteligencia (API Claude):** el modelo `claude-sonnet-4-20250514` de Anthropic recibe en cada llamada el system prompt completo con el contexto del proyecto y el historial de conversación acumulado, generando respuestas contextualizadas con recomendaciones de visualización incluidas.

4.5.2 Diseño del system prompt

La instrucción del sistema, o más comúnmente el system prompt, es el elemento central del agente. Se envía en cada llamada a la API junto con el historial de conversación, encapsulando todo el conocimiento del proyecto:

```
1 SYSTEM_PROMPT = """Eres un asistente experto en análisis
2 de demanda de neumáticos en el mercado suizo...
3
4 CRITERIO DE FIABILIDAD (MAPE walk-forward):
5 - MAPE < 25%: MUY FIABLE
6 - MAPE 25-50%: ACEPTABLE
7 - MAPE 50-100%: DEBIL
```

```

8 - MAPE > 100%: IMPREDECIBLE
9
10 ENSEMBLE DEFINITIVO:
11 Aargau: XGB_Bayes, 15.0%, 23.582 uds MUY FIABLE
12 [...26 cantones con modelo, MAPE y predicción...]
13
14 GRÁFICAS DISPONIBLES:
15 [GRAFICA_RECOMENDADA: nombre_grafica]
16 Al final de cada respuesta relevante indica la gráfica
17 más adecuada con este formato exacto.
18 """

```

Listing 4.20: Estructura del system prompt del agente.

La instrucción de recomendación de gráficas al final del prompt es clave: Flask extrae la etiqueta mediante expresión regular y genera automáticamente la visualización:

```

1 import re
2 from anthropic import Anthropic
3
4 def extraer_grafica(texto):
5     match = re.search(
6         r'\[GRAFICA_RECOMENDADA:\s*(\w+)\]', texto)
7     if match:
8         nombre = match.group(1)
9         texto_limpio = re.sub(
10             r'\[GRAFICA_RECOMENDADA:\s*\w+\]',
11             '', texto).strip()
12         return nombre, texto_limpio
13     return None, texto
14
15 @app.route('/chat', methods=['POST'])
16 def chat():
17     mensaje = request.get_json()['mensaje']
18     historial.append({'role': 'user',
19                     'content': mensaje})
20     client = Anthropic(api_key=API_KEY)
21     response = client.messages.create(
22         model='claude-sonnet-4-20250514',
23         max_tokens=1000,
24         system=SYSTEM_PROMPT,
25         messages=historial
26     )
27     respuesta = response.content[0].text
28     historial.append({'role': 'assistant',
29                     'content': respuesta})
30     nombre_grafica, respuesta_limpia = \
31         extraer_grafica(respuesta)
32     fig_data = generar_grafica(nombre_grafica) \
33         if nombre_grafica else None
34     return jsonify({
35         'respuesta': respuesta_limpia,
36         'grafica': fig_data,
37         'nombre_grafica': nombre_grafica
38     })

```

Listing 4.21: Extracción de la gráfica recomendada y llamada a la API.

4.5.3 Integración con Tableau

El panel de control de Tableau Public se integra en la interfaz del agente mediante un iframe en el HTML:

```
1 <iframe
2   id="tableauIframe"
3   src="https://public.tableau.com/views/
4       Exposicion_resultados_TFG/Dashboard_Principal
5       ?:embed=y&:showVizHome=no&:toolbar=yes"
6   allowfullscreen>
7 </iframe>
```

Listing 4.22: Integración del panel de control de Tableau como iframe.

La interfaz final presenta dos pestañas en el panel derecho: Panel de control de Tableau (para exploración visual empresarial) y Gráficas de análisis (para visualizaciones técnicas generadas por el agente). Cada respuesta del chat incluye dos botones de acceso rápido: uno para ver la gráfica Plotly recomendada y otro para ir directamente al panel de control de Tableau.

Los resultados completos del agente y el panel de control se presentan en el Capítulo 5.

5 RESULTADOS

5.1 Resultados del análisis exploratorio de datos

5.1.1 Análisis temporal

El análisis temporal confirmó las hipótesis planteadas en el Capítulo 3 sobre la estacionalidad y el desfase entre canales. La Figura 5.1 muestra la estabilidad interanual del patrón bimodal, con picos consistentes en marzo-abril (cambio a neumáticos de verano) y septiembre-octubre (cambio a neumáticos de invierno) en el período de 2018-2026.




Figura 5.1: Estacionalidad normalizada del Sell Out por año (2022-2025). Los cuatro años muestran un patrón prácticamente idéntico, confirmando la estabilidad de la demanda bimodal.

El análisis de correlación con la temperatura confirmó que la relación directa (desfase de 0 meses) no es significativa para ningún tipo de neumático, pero se vuelve altamente significativa a partir de un desfase de dos meses: $r = 0,535$ para neumático Winter y $r = -0,446$ para neumático Summer, ambos con $p < 0,001$. Los neumáticos All Season no presentan correlación significativa con la temperatura en ningún desfase, lo que sugiere que su compra responde a criterios de conveniencia y no a la climatología.




Figura 5.2: Correlación entre ventas y temperatura con lag de 2 meses para neumáticos Winter (izquierda) y Summer (derecha).

El desfase entre Sell In y Sell Out es de aproximadamente dos meses, confirmado tanto visualmente como mediante análisis de correlación cruzada, lo que implica que el aprovisionamiento del canal precede a la venta al consumidor final.

El gap medio mensual entre Sell In y Sell Out es del 24,1 %, con tendencia bajista desde 2024 que sugiere una optimización progresiva de la gestión de inventario por parte de los distribuidores, como se puede ver en la Figura 5.3




Figura 5.3: La gráfica superior representa el volumen mensual de Sell In y Sell Out, donde se puede observar la tendencia bajista en cuanto al stock presente en las empresas. La inferior representa la acumulación (negativa o positiva), que hace que sugiera que sea un ajuste de inventario por los grandes volúmenes de aprovisionamiento previos

El precio medio por neumático pasó de 80 CHF en 2023 a 95 CHF en 2026, un incremento del 18 % en tres años, coherente con la presión inflacionaria moderada experimentada en Suiza durante el período, como se puede ver en la Figura 5.4




Figura 5.4: La gráfica superior representa la evolución del precio medio de los neumáticos donde se puede ver la tendencia alcista del precio. La inferior muestra el precio medio por mes del precio medio de los neumáticos lo que muestra consistencia en ellos y apuntando a que el crecimiento del precio es debido a temas inflacionarios.

5.1.2 Análisis geográfico

El análisis geográfico confirmó la existencia de un outlier logístico significativo y reveló importantes diferencias de penetración entre cantones. La Figura 5.5 muestra la diferencia normalizada entre el Sell Out y el Tire Potential por cantón, identificando las zonas con mayor potencial de crecimiento.




Figura 5.5: Diferencia normalizada Sell Out vs Tire Potential por cantón (sin Solothurn por efecto logístico). Verde = potencial de crecimiento, rojo = alta penetración de las empresas reportantes.

Los resultados geográficos más relevantes son:

- El CP 4624 (Härkingen, Solothurn) acumula el 17,2 % del volumen total del Sell Out, correspondiente al centro logístico de una de las empresas reportantes. Este efecto se excluye de las visualizaciones geográficas pero se mantiene en el modelado cantonal al ser demanda real.
- Los cantones de Genève (42,7 % de cobertura respecto al Tire Potential), SanktGallen (54,6 %) y Schaffhausen (29,3 %) presentan el mayor potencial de crecimiento relativo para las empresas reportantes.
- El porcentaje de neumáticos premium correlaciona positivamente con el PIB per cápita cantonal: Basel-Landschaft (39,1 %) y Zug (39,0 %) frente a Nidwalden (21,4 %).
- Se identifica una separación geográfica clara entre zonas de aprovisionamiento (noroeste francófono: Vaud, Neuchâtel) y zonas de consumo final (sur alpino: Ticino), con los Alpes actuando como barrera logística natural.

5.1.3 Análisis de producto

El análisis de producto reveló dos tendencias estructurales claras: la premiumización acelerada del mercado y la migración hacia llantas de mayor diámetro, ambas vinculadas al fenómeno global de SUVización del parque vehicular, como se pueden ver en la Figura 5.6 y en la Figura 5.7 respectivamente.




Figura 5.6: Evolución de la mezcla por tipo de neumático por año (2018-2026). Premium pasa del 28 % al 80 % en el período analizado, con el sorpasso sobre Quality en 2019.




Figura 5.7: Evolución del diámetro de llanta (RIM) por año (2019-2026). RIM 16 cae del 37 % al 22 % mientras RIM 18 sube del 10 % al 21 %.

Los resultados más destacados son:

- Premium ha pasado del 28 % al 80 % del total de ventas en el período 2018-2026, con el sorpasso sobre Quality en 2019. El segmento Budget prácticamente desapareció del mercado suizo a partir de ese año.
- RIM 16 ha caído del 37 % al 22 % del total (2019-2026), mientras RIM 18 ha subido del 10 % al 21 %, reflejo de la SUVización del parque vehicular.
- El segmento Passenger domina con el 70,3 % del volumen de Sell In, seguido de 4x4 con el 22,5 %, porcentaje elevado que refleja la geografía alpina suiza.
- El segmento Run on Flat muestra una tendencia descendente (1,66 % en 2023 a 1,48 % en 2025), concentrado exclusivamente en vehículos Passenger.

5.2 Resultados del modelado predictivo

5.2.1 Comparativa de modelos

La Tabla 5.1 resume los resultados de todos los modelos evaluados a lo largo del proceso de desarrollo descrito en el Capítulo 4, medidos con MAPE walk-forward (media de 3 cortes temporales).

Antes de interpretar la tabla conviene aclarar dos aspectos. Primero, el ámbito indica sobre qué cantones se evaluó cada modelo: Grandes son los 13 cantones con volumen medio superior a 500 unidades/mes y Global incluye los 26 cantones. Segundo, aunque el ensemble definitivo muestra un MAPE global del 59,9 %, aparentemente peor que la media histórica, esto se debe a dos razones: los modelos individuales se evaluaron sobre un único corte train/test mientras que el conjunto de modelos (Ensemble) usa walk-forward con tres cortes, una validación más estricta; y el promedio global incluye cantones como Uri o Appenzell Ausserrhoden con MAPEs superiores al 250 % que elevan artificialmente la media. En los cantones grandes, donde el ensemble es aplicable de forma fiable, el MAPE baja al 28,8 %, muy por debajo de cualquier baseline.

Cuadro 5.1: Comparativa de MAPE walk-forward por modelo. Grandes: 13 cantones con volumen medio ≥ 500 uds/mes. Todos: los 26 cantones. Global: promedio del conjunto de modelos (Ensemble) con el modelo óptimo por cantón. El mejor resultado de cada grupo se muestra en negrita.

Modelo	MAPE	Ámbito	Observación
<i>Modelos de referencia (baselines)</i>			
Baseline Naive	66,4 %	Global	Referencia mínima
Baseline Media histórica	50,9 %	Global	Referencia mínima
<i>Modelos individuales evaluados</i>			
SARIMA	42,2 %	Grandes	Gana en cantones estacionales
ETS	$\approx 40,0$ %	Todos	Competitivo en cantones pequeños
XGBoost v1 (Grid Search)	39,0 %	Grandes	Sin mejora sobre v1 inicial
XGBoost v2 (variables macro)	32,6 %	Grandes	Mejora del 16 % sobre v1
XGBoost Bayes (Optuna)	29,3 %	Grandes	Mejor modelo individual
<i>Ensemble definitivo (walk-forward, 3 cortes)</i>			
Ensemble definitivo	59,9 %	Global	Validación más estricta
Ensemble definitivo	28,8 %	Grandes	Mejor resultado en cantones fiables
Ensemble definitivo (sin Uri/AA)	40,1 %	Global	Sin cantones impredecibles

5.2.2 Ensemble definitivo

El ensemble definitivo es el resultado final de todas las iteraciones de modelado descritas en el Capítulo 4. Asigna a cada cantón el modelo con menor MAPE *walk-forward*, obteniendo los siguientes resultados globales:

- **MAPE medio global:** 59,9 % (26 cantones).
- **MAPE medio cantones grandes:** 28,8 % (13 cantones), considerado buen resultado para predicción de demanda industrial (Syntetos & Boylan, 2005).
- **MAPE medio cantones pequeños:** 91,1 % (13 cantones), fuertemente influido por dos cantones con demanda prácticamente impredecible.
- **Cantones por debajo del umbral del 50 %:** 20 de 26 (77 %).

El MAPE por cantón y la distribución de modelos dentro del ensemble se puede ver en la Figura 5.8.




Figura 5.8: Ensemble definitivo: MAPE walk-forward por cantón (izquierda) y distribución de modelos asignados (derecha). La línea discontinua marca el umbral del 50 %.

Cantones problemáticos: Uri y AppenzellAusserrhoden presentan MAPEs del 252,1 % y 332,3 % respectivamente, con desviaciones estándar de 247,1 y 367,9 puntos porcentuales. Estos cantones son prácticamente impredecibles por tres razones:

- **Volumen insuficiente:** Uri tiene una media de 48 unidades/mes y AppenzellAusserrhoden de 58. Con estos volúmenes, un único pedido extraordinario puede triplicar el valor habitual, generando errores relativos enormes independientemente del modelo empleado.
- **Alta varianza:** la desviación estándar del volumen mensual supera en ambos casos a la media, lo que matemáticamente impide que cualquier predictor basado en el histórico pueda ser preciso.
- **Irregularidad estructural:** la demanda no responde a patrones estacionales sino a pedidos individuales de pocos clientes, comportamiento esencialmente estocástico.

Si se excluyen estos dos cantones, el MAPE medio global pasa del 59,9 % al 40,1 %, con 20 de 24 cantones por debajo del umbral del 50 %. Este valor es más representativo del rendimiento real del sistema, ya que Uri y AppenzellAusserrhoden representan conjuntamente menos del 0,4 % del volumen total de Suiza.

Los parámetros detallados de cada modelo del ensemble definitivo, incluyendo los hiperparámetros de XGB_Bayes obtenidos mediante optimización bayesiana y los de XGB_v2, así como las variables exógenas de SARIMAX, se recogen en el Anexo C de este documento..

5.2.3 Predicciones para el período marzo 2026 - febrero 2027

La Tabla 5.2 muestra las predicciones totales a 12 meses por cantón generadas con el ensemble definitivo.

La predicción para Suiza es de 320.309 unidades en los próximos 12 meses. Solothurn lidera por el efecto logístico del centro de distribución de Härkingen, seguido de Zürich y Vaud como los grandes mercados reales del país.




Figura 5.9: Mapa de predicción de demanda a 12 meses por cantón (izquierda, sin Solothurn por efecto logístico) y MAPE walk-forward por cantón (derecha). Verde = mejor precisión.

Cuadro 5.2: Predicciones de demanda a 12 meses por cantón (marzo 2026 - febrero 2027).

Cantón	Modelo	Predicción 12m (uds)
Solothurn	XGB_Bayes	64.782
Zürich	XGB_Bayes	49.346
Vaud	SARIMAX	30.632
Bern	XGB_Bayes	26.983
Ticino	XGB_Bayes	23.660
Aargau	XGB_Bayes	23.582
Fribourg	XGB_v2	13.438
Valais	XGB_Bayes	11.668
SanktGallen	XGB_v2	10.561
Lucerne	XGB_v2	9.509
Graubünden	XGB_Bayes	9.434
Basel-Landschaft	XGB_v2	7.133
Schwyz	XGB_v2	6.578
Thurgau	XGB_v2	5.880
Basel-Stadt	XGB_v2	5.642
Genève	SARIMA	5.360
Neuchâtel	XGB_v2	4.359
Zug	XGB_Bayes	3.719
Jura	XGB_v2	2.583
Nidwalden	XGB_v2	2.476
Glarus	Media	733
Schaffhausen	XGB_v2	589
Obwalden	Media	566
Uri	XGB_v2	553
AppenzellAusserrhoden	Media	496
AppenzellInnerrhoden	Ridge	48
Total Suiza	Ensemble	320.309

5.3 Resultados del panel de control

El panel de control desarrollado en Tableau Public integra las cinco vistas descritas en el Capítulo 4 con dos filtros globales (cantón y modelo) implementados mediante parámetros. La Figura 5.10 muestra la vista general del panel de control.




Figura 5.10: Vista general del panel de control principal en Tableau Public con los filtros globales de cantón y modelo activos en la parte superior.

Las principales funcionalidades del panel de control son:

- **Filtro de cantón:** al seleccionar un cantón en el desplegable, todas las vistas se actualizan simultáneamente mostrando el histórico, la predicción, el mix de producto y la estacionalidad del cantón seleccionado (Flecha azul).
- **Filtro de modelo:** permite mostrar únicamente los cantones asignados a un modelo específico, facilitando la comparación entre enfoques metodológicos (Flecha roja).
- **Tooltip informativo en el mapa:** al pasar el cursor sobre cada cantón muestra el nombre, la predicción a 12 meses, el modelo asignado y el MAPE walk-forward (Flecha Verde).

5.4 Resultados del agente conversacional

El agente conversacional integra el panel de control de Tableau Public y las gráficas de análisis en una única interfaz web, permitiendo obtener interpretaciones automáticas en lenguaje natural sobre los resultados del proyecto. Esta interfaz se puede observar en la Figura 5.11.




Figura 5.11: Interfaz del agente conversacional en funcionamiento: panel de chat (izquierda) y panel de control de Tableau integrado (derecha).

A modo de ejemplo, ante la pregunta “¿Son fiables las predicciones para Uri?”, el agente genera la siguiente respuesta, además de generar la tabla más acorde a la pregunta, como se puede ver en la Figura 5.12:

Respuesta del agente

Predicciones para Uri: IMPREDECIBLE

Las predicciones para Uri son las menos fiables de todo el proyecto, con diferencia.

Métrica	Valor
Modelo	XGB_v2
MAPE	252,1 %
Desviación estándar	±247,1 pp
Predicción 12 meses	553 unidades
Volumen medio mensual	≈48 unidades
Umbral de fiabilidad	>100 % → IMPREDECIBLE

¿Por qué es impredecible?

La causa raíz no es un fallo del modelo, sino la naturaleza estructural de la demanda en Uri:

- Volumen extremadamente bajo: 48 unidades al mes, lo que equivale a 1-2 clientes activos en el cantón.
- Demanda estocástica: un único pedido extraordinario puede triplicar o cuadruplicar el valor habitual, haciendo que cualquier predicción sea errónea.
- Desviación estándar de ±247 pp: el error varía de forma masiva entre los distintos cortes temporales del walk-forward, lo que indica ausencia de patrón estable.
- Ningún modelo puede capturar comportamientos dependientes de decisiones individuales de 1-2 compradores.

Implicación práctica para el negocio

>No utilizar las predicciones de Uri para planificación de stock.

La recomendación operativa es gestionar Uri mediante stock de seguridad fijo o reposición reactiva, en lugar de previsión estadística. Uri representa menos del 0.4 % del volumen total de Suiza (553 uds / 320.309 uds), por lo que su impacto en la planificación global es completamente marginal.




Figura 5.12: Gráfica de análisis generada automáticamente por el agente tras la consulta sobre Uri. El agente recomendó la vista de MAPE por cantón para contextualizar la fiabilidad.

Las principales capacidades demostradas son:

- **Interpretación de fiabilidad por cantón:** el agente clasifica automáticamente cada cantón según el criterio de fiabilidad definido en el system prompt y justifica la clasificación con los datos del conjunto de modelos.
- **Resúmenes ejecutivos:** sintetiza los resultados globales del proyecto en un formato comprensible para perfiles no técnicos.
- **Recomendación contextual de gráficas:** identifica automáticamente la visualización más relevante para cada tipo de pregunta y la genera sin intervención del usuario.
- **Soporte al panel de control de Tableau:** cada respuesta incluye un acceso directo al panel de control para contrastar la interpretación del agente con la vista interactiva de los datos.

5.5 Comparativa con trabajos similares

En la competición de predicción M4 (Makridakis et al., 2018), los métodos de conjuntos de modelos estadístico obtuvieron MAPEs medios de entre el 13 % y el 18 % para series mensuales. Sin embargo, estas series presentan mayor regularidad y volumen que los cantones pequeños suizos, lo que hace la comparación directa poco apropiada.

Para series de demanda territorial con alta heterogeneidad entre zonas, resultados en el rango del 25-45 % de MAPE se consideran competitivos en la literatura aplicada (Syntetos & Boylan, 2005). El resultado del conjunto de modelos definitivo (28,8 % para cantones grandes, 40,1 % global excluyendo los dos cantones impredecibles) se sitúa dentro de este rango.

La incorporación de la optimización bayesiana de hiperparámetros supone una mejora del 25 % sobre el *grid search* (29,3 % vs. 39,0 %), resultado coherente con los reportados en la literatura de AutoML (Feurer et al., 2015).

6 CONCLUSIONES y TRABAJOS FUTUROS

6.1 Conclusiones

En este trabajo se ha desarrollado un sistema completo de análisis y predicción de la demanda de neumáticos por cantón en el mercado suizo, abarcando desde la preparación de datos hasta el despliegue de un dashboard interactivo con un agente conversacional que lo complementa.

1. La estacionalidad bimodal es el patrón dominante y altamente predecible. El mercado suizo de neumáticos presenta picos de demanda consistentes en primavera (cambio a verano) y otoño (cambio a invierno), correlacionados significativamente con la temperatura con un desfase de dos meses ($r = 0,535$ para tipo de neumático Winter). Este patrón es altamente estable interanualmente, lo que facilita la predicción en los cantones con suficiente volumen histórico.

2. No existe un modelo universalmente superior. El análisis comparativo de seis familias de modelos demuestra que la elección óptima depende del volumen histórico disponible, la estabilidad del patrón estacional y la disponibilidad de variables de contexto. XGBoost con optimización bayesiana domina en cantones grandes (77 % de los casos), SARIMA y SARIMAX son competitivos en cantones con estacionalidad muy marcada, y la media histórica es el mejor predictor para cantones con volumen insuficiente para modelos complejos.

3. La optimización bayesiana supera significativamente al grid search. Optuna con 100 iteraciones alcanzó un MAPE del 29,3 % frente al 39,0 % del grid search con 54 combinaciones, una mejora del 25 % con menor coste computacional por evaluación, al Optuna aprender de la evaluación anterior y proponer mejores configuraciones y Grid Search evaluar exhaustivamente todas las combinaciones posibles de hiperparámetros. Esta diferencia justifica el uso de métodos de búsqueda inteligente en proyectos de predicción de demanda territorial.

4. Las variables macroeconómicas y del parque vehicular mejoran la predicción. La incorporación de CPI, inflación interanual, tamaño del parque vehicular y porcentaje de vehículos eléctricos por cantón redujo el MAPE de XGBoost del 38,8 % al 32,6 %, una mejora del 16 %. Aunque individualmente modestas, estas variables capturan el contexto económico y estructural de cada zona.

5. La heterogeneidad cantonal requiere un enfoque ensemble. Los 26 cantones suizos presentan perfiles de demanda radicalmente distintos, desde más de 5.000 unidades mensuales en Solothurn hasta menos de 10 en Appenzell Innerrhoden. Esta heterogeneidad hace inviable cualquier modelo único y justifica la selección del modelo óptimo por cantón.

6. El sistema tiene limitaciones inherentes en cantones de muy bajo volumen. Uri y Appenzell Ausserrhoden presentan MAPEs del 252 % y 332 % respectivamente, siendo prácticamente impredecibles debido a su bajo volumen (<60 unidades/mes de media) y alta irregularidad. Excluyendo estos dos cantones, el MAPE medio del ensemble pasa del 59,9 % al 40,1 %, con un 83 % de cantones por debajo del umbral aceptable del 50 %.

7. La validación mediante validación cruzada walk-forward es más realista que el corte único. La validación con tres cortes temporales produjo un MAPE medio global del 59,9 % frente al 29,8 % obtenido con un único corte train/test, lo que demuestra que el corte único sobreestima el rendimiento real del modelo al evaluar solo un período favorable. El MAPE del 59,9 % es por tanto la estimación más realista del error esperado en producción, y es el valor que se toma como referencia para evaluar la calidad del sistema.

6.2 Objetivos cumplidos

- **OE1 - Preparación de datos:** completado. Pipeline de limpieza, anonimización con mapeos consistentes y enriquecimiento geográfico mediante spatial join sobre los cinco datasets disponibles.
- **OE2 - Análisis exploratorio:** completado. Análisis multidimensional (temporal, geográfico y de producto) con identificación de patrones estacionales, zonas de oportunidad y tendencias estructurales del mercado.
- **OE3 - Modelado predictivo:** completado. Comparativa de seis familias de modelos validados con walk-forward cross-validation, construcción del ensemble definitivo con optimización bayesiana e incorporación de variables macroeconómicas.
- **OE4 - Dashboard interactivo:** completado. Dashboard en Tableau Public con cinco vistas integradas y filtros globales por cantón y modelo.
- **OE5 - Agente conversacional:** completado. Aplicación Flask con interfaz web que integra el dashboard de Tableau como capa de presentación y un agente basado en la API de Claude (Anthropic, 2024) como capa de interpretación inteligente.

6.3 Trabajos futuros

A pesar de que los resultados obtenidos sean satisfactorios, hay cierto margen de mejora posible que podría explorarse en futuros trabajos:

Modelado con Prophet: la librería Prophet de Meta, diseñada específicamente para series temporales con estacionalidad múltiple y eventos especiales, no pudo evaluarse en este trabajo por incompatibilidades técnicas con el entorno Windows. Su inclusión en el ensemble podría mejorar los resultados en cantones con patrones estacionales complejos.

Modelos de aprendizaje profundo: la exploración de arquitecturas LSTM o Transformer para series temporales podría capturar dependencias temporales no lineales que los modelos actuales no modelan. El tamaño del dataset (94 meses por cantón) es un factor limitante, pero podría mitigarse con transferencia de aprendizaje entre cantones.

Datos de matriculaciones mensuales: el carpark disponible solo contiene datos de 2026, lo que impide capturar la dinámica temporal del parque vehicular. La incorporación de datos de matriculaciones mensuales por cantón permitiría modelar el impacto temporal de la electrificación y la SUVización sobre la demanda de neumáticos.

Predicción a nivel de código postal: el modelo actual opera a nivel cantonal. Una extensión natural sería desarrollar predicciones para los 300 códigos postales que concentran el 80 % del volumen, lo que permitiría una planificación logística más granular.

Expansión del agente conversacional: el agente actual utiliza un system prompt estático con los datos del proyecto. Una evolución natural sería conectarlo directamente a los CSVs de datos para que pueda responder preguntas sobre períodos o cantones específicos con datos actualizados en tiempo real, sin necesidad de actualizar manualmente el contexto del prompt. Asimismo, la incorporación de herramientas de ejecución de código permitiría al agente generar análisis estadísticos ad hoc a partir de los datos brutos, ampliando significativamente sus capacidades de interpretación.

7 BIBLIOGRAFÍA

Las citas deben ser realizadas bajo la Norma APA.

- Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2623-2631. <https://doi.org/10.1145/3292500.3330701>
- Anaconda, Inc. (2020). *Anaconda Distribution*. Consultado el 1 de mayo de 2026, desde <https://www.anaconda.com>
- Anthropic. (2024). The Claude 3 model family: Opus, Sonnet, Haiku. Consultado el 1 de mayo de 2026, desde <https://www.anthropic.com/news/claude-3-family>
- Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13, 281-305.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.^a ed.). Wiley.
- Chase, C. W. (2013). *Next generation demand management: People, process, analytics, and technology*. Wiley.
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Dietterich, T. G. (2000). Ensemble methods in machine learning. En *Multiple classifier systems* (pp. 1-15). Springer. https://doi.org/10.1007/3-540-45014-9_1
- Feurer, M., Klein, A., Eggenberger, K., Springenberg, J. T., Blum, M., & Hutter, F. (2015). Efficient and robust automated machine learning. *Advances in Neural Information Processing Systems*, 28.
- GADM. (2022). Global administrative areas database, version 4.1. Consultado el 1 de mayo de 2026, desde <https://gadm.org>
- Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585, 357-362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55-67. <https://doi.org/10.1080/00401706.1970.10488634>
- Holt, C. C. (2004). Forecasting seasonals and trends by exponentially weighted moving averages. *International Journal of Forecasting*, 20(1), 5-10. <https://doi.org/10.1016/j.ijforecast.2003.09.015>
- Jordahl, K., Van den Bossche, J., Fleischmann, M., et al. (2021). GeoPandas: Python tools for geographic data. *Journal of Open Source Software*, 6(65), 3424. <https://doi.org/10.21105/joss.03424>
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). The M4 competition: Results, findings, conclusion and way forward. *International Journal of Forecasting*, 34(4), 802-808. <https://doi.org/10.1016/j.ijforecast.2018.06.001>
- McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 445, 51-56. <https://doi.org/10.25080/Majora-92bf1922-00a>
- Open-Meteo. (2022). Open-Meteo weather API. Consultado el 1 de mayo de 2026, desde <https://open-meteo.com>
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Plotly Technologies Inc. (2015). *Collaborative data science*. Consultado el 1 de mayo de 2026, desde <https://plot.ly>

- Ronacher, A. (2010). *Flask: A lightweight WSGI web application framework*. Consultado el 1 de mayo de 2026, desde <https://flask.palletsprojects.com>
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92-96. <https://doi.org/10.25080/Majora-92bf1922-011>
- Snoek, J., Larochelle, H., & Adams, R. P. (2012). Practical Bayesian optimization of machine learning algorithms. *Advances in Neural Information Processing Systems*, 25, 2951-2959.
- Syntetos, A. A., & Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting*, 21(2), 303-314. <https://doi.org/10.1016/j.ijforecast.2004.10.001>
- Tableau Software, LLC. (2024). *Tableau Public*. Consultado el 1 de mayo de 2026, desde <https://public.tableau.com>
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437-450. [https://doi.org/10.1016/S0169-2070\(00\)00065-0](https://doi.org/10.1016/S0169-2070(00)00065-0)
- Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science*, 6(3), 324-342. <https://doi.org/10.1287/mnsc.6.3.324>
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*, 29-39.
- World Bank. (2023). World development indicators: Consumer price index. Consultado el 1 de mayo de 2026, desde <https://databank.worldbank.org/source/world-development-indicators>

8 ANEXOS

A Declaración de uso de IAG

De conformidad con la política de la Universidad Intercontinental de la Empresa sobre el uso de herramientas de Inteligencia Artificial Generativa (IAG) en los Trabajos Fin de Grado, el autor declara haber utilizado herramientas de IAG como apoyo en la elaboración del presente trabajo.

Herramientas utilizadas: Claude (Anthropic), Gemini (Google) y DeepSeek.

Finalidad del uso: las herramientas de IAG se utilizaron en las siguientes tareas: apoyo en escritura y redacción (revisión ortográfica, mejora de párrafos, reformulación de ideas y generación de esquemas); consulta y documentación (explicaciones conceptuales, búsqueda de referencias preliminares y respuestas a preguntas técnicas); diseño y metodología (propuesta de metodologías, tratamiento y análisis de datos, procesos de optimización y generación de visualizaciones); y generación de código (fragmentos de código, depuración de errores, propuesta de algoritmos y generación de módulos y APIs).

Protección de datos: los datos personales y confidenciales del cliente fueron anonimizados en un entorno controlado por la empresa y aprobados por sus responsables antes de ser trasladados al entorno personal de trabajo. Las 17 columnas sensibles identificadas fueron sustituidas por identificadores genéricos mediante mapeos consistentes entre datasets.

Responsabilidad académica: el autor declara que el contenido intelectual del trabajo, incluyendo el diseño metodológico, el análisis de resultados y las conclusiones, es de su autoría. Las herramientas de IAG han sido utilizadas como apoyo y su output ha sido supervisado, verificado y validado por el autor en todo momento.

B Repositorio y panel de control

Repositorio del proyecto en Github: <https://github.com/mronceroo/Prediccion-de-demanda-de-empresa-de-produccion-de-neumaticos-en-Suiza/tree/main>

Panel de control en Tablau Public: <https://n9.cl/kaue5>

C Parámetros del ensemble definitivo

La Tabla C.1 recoge los hiperparámetros utilizados por cada versión de XGBoost en el ensemble definitivo.

Cuadro C.1: Hiperparámetros de los modelos XGBoost en el ensemble definitivo.

Parámetro	XGB_v2	XGB_Bayes
n_estimators	500	475
max_depth	3	5
learning_rate	0,030	0,058
subsample	0,800	0,662
colsample_bytree	0,800	0,614
min_child_weight	1	5
random_state	42	42

Los parámetros de XGB_Bayes fueron obtenidos mediante optimización bayesiana con Optuna (100 iteraciones, algoritmo TPE) sobre el espacio de búsqueda:

- n_estimators: [100, 600]
- max_depth: [2, 6]
- learning_rate: [0,01, 0,15] (escala logarítmica)
- subsample: [0,6, 1,0]
- colsample_bytree: [0,6, 1,0]
- min_child_weight: [1, 10]

Los parámetros de SARIMA y SARIMAX para todos los cantones son $(1, 1, 1)(1, 1, 1)_{12}$, configuración estándar para series mensuales con estacionalidad anual. Las variables exógenas de SARIMAX son: CPI, inflación interanual, total de vehículos por cantón, porcentaje de vehículos eléctricos, temperatura con desfase de 2 meses y nieve con desfase de 2 meses.